面向基于混合专家的稳健四足运动：提升仿真到现实迁移的可靠可预测性

Toward Reliable Sim-to-Real Predictability for MoE-based Robust Quadrupedal Locomotion

匿名评审稿，作者姓名未公开 论文编号：1098

项目页：https://robogauge.github.io/ 代码入口：训练、评估、部署

译稿说明：以用户提供的 anonymous.pdf（16页）为唯一翻译底本，完整翻译正文、附录 A—D、全部图注与13张表，保留18幅原图和11个编号公式。原表 XI—XIII 为便于单栏阅读分组呈现；58条参考文献保留英文著录以便检索。灰底“重点解释”和末尾深入解读均为译者补充。项目页自列 RSS、2026，且署名 Anonymous，因此文件名前缀注明“RSS匿名投稿稿”，不将其视为已录用或正式出版的证明。原文存在公式、种子数、评分口径等疑点，均照录并说明，不替作者修改实验事实。单栏连续排版，无独立封面和自测题。

摘要

强化学习在四足机器人的敏捷运动方面展现出巨大潜力，即使仅依赖本体感知也能取得良好效果。然而，在实践中，仿真到现实的差距以及复杂地形上的奖励过拟合，可能使策略无法迁移到实机，而物理验证仍然危险且低效。为应对这些问题，我们提出一个统一框架，将用于稳健多地形表征的混合专家（Mixture-of-Experts，MoE）运动策略，与量化仿真到现实迁移能力的预测性评估套件 RoboGauge 结合起来。MoE 策略利用受门控网络调节的一组专长专家，将地形与指令的隐变量建模分解开，仅凭本体感知便获得更好的部署稳健性和泛化能力。

RoboGauge 进一步通过覆盖地形、难度等级和域随机化的仿真到仿真测试，提供基于本体感知的多维指标，使人们无需大量实机试验即可可靠地选择 MoE 策略。在宇树 Unitree Go2 上的实验表明，机器人能够稳健通过未见过的困难地形，包括积雪、沙地、楼梯、斜坡和30 cm障碍物。在专门的高速测试中，机器人达到4 m/s，并涌现出与高速稳定性改善相关的窄幅步态。

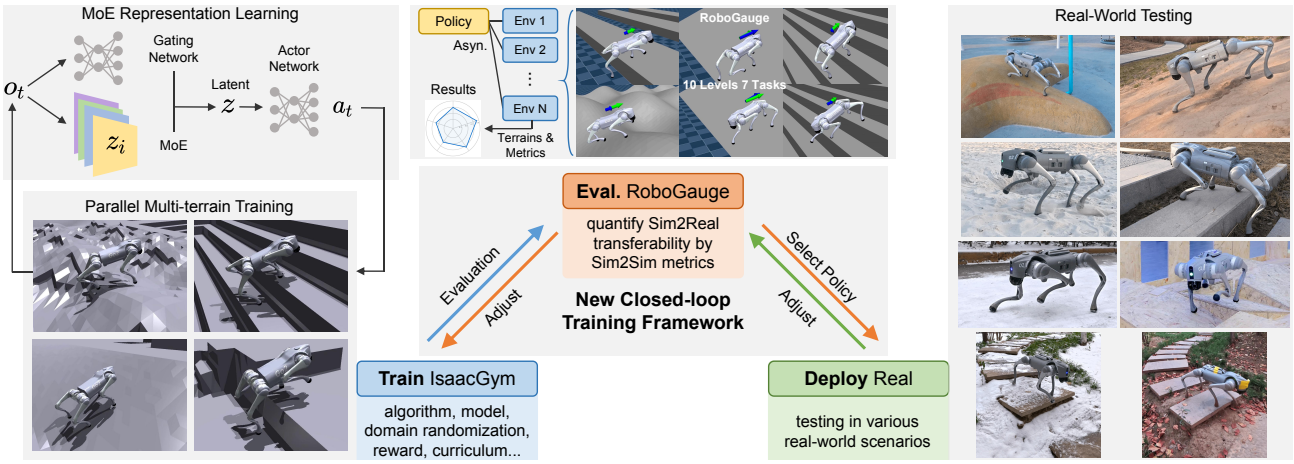


图1 作者提出的框架将用于地形与指令表征的混合专家架构，与 RoboGauge 评估套件结合，利用仿真到仿真指标量化仿真到现实的迁移能力。这种闭环设计支持可靠的策略选择，从而使机器人仅凭本体感知，便能在多种困难环境中稳健部署敏捷运动。

图内英文对照：MoE Representation Learning：混合专家表征学习；Gating Network：门控网络；Actor Network：行动者网络；Latent：隐变量；Parallel Multi-terrain Training：并行多地形训练；Env/Policy：环境/策略；Asyn.：异步；10 Levels 7 Tasks：10级、7类任务；Terrains & Metrics/Results：地形与指标/结果；Train IsaacGym：在 IsaacGym 中训练；Eval. RoboGauge：用 RoboGauge 评估；Deploy Real：实机部署；Adjust/Select Policy：调整/选择策略；New Closed-loop Training Framework：新的闭环训练框架；算法、模型、域随机化、奖励、课程等均可按反馈调整。

【重点解释】 全文有两条主线：MoE 改善策略内部表征，RoboGauge 改善策略外部筛选。前者回答“怎样学得更好”，后者回答“训练得分高的策略是否值得上实机”。跨仿真得分是迁移能力的代理指标，其可信度需要实机数据验证，不能等同于物理安全保证。

I 引言

机器人经常在复杂、动态的环境中工作，因此需要很强的机动能力[19,18,14]。四足机器人凭借出色的机动性和环境适应能力，受到广泛关注[3,10,45,6,9,5,12,20,27,32,54,55]。强化学习通过与仿真环境持续交互，不断优化策略，已经成为增强机器人运动稳健性的有力方法[24,23,46,16,51,45,52,41,33,36,28,31,8,30,53]。

仿真到现实的固有差距仍是主要障碍，因为基于仿真的性能指标往往无法可靠反映实际部署效果[22,47,38,1,4]。尤其是在多种地形上获得很高训练奖励，也不能保证实机稳定：策略容易过拟合仿真机器人的特定动力学，使其在真实硬件上的泛化能力下降[24,23,21]。此外，缺少可靠的定量代理指标，迫使研究人员依赖直接实机验证，而这种过程风险高、效率低[10,45,52]。

为缓解这些问题，我们提出一种训练框架，将地形与指令表征的 MoE 架构和 RoboGauge 评估套件整合起来。MoE 仅依赖本体感知来编码未知地形和指令，从而提升建模能力，同时避免使用相机、激光雷达或足部接触传感器。这些传感器常会在浓烟、照明不足或剧烈振动等极端条件下失效。为配合策略迭代架构，我们开发 RoboGauge 预测性评估框架，通过并行的仿真到仿真方法，利用6个不同指标，覆盖7种地形、10个难度等级、3种目标和4类域随机化，量化仿真到现实的稳定性。

图2展示了不同模型在 RoboGauge 中针对七种地形的性能分布。我们的 MoE 策略在每一种地形类别上均优于所有基线方法，表现出全面优势。该方法在真实机器人部署中也展现出出色的性能。

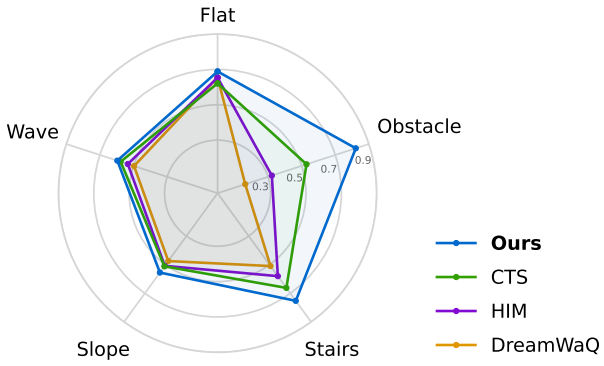


图2 与 CTS、HIM、DreamWaQ 等单阶段本体感知方法进行比较。在 RoboGauge 框架中，每条轴表示某种地形上的平均性能，并作为量化仿真到现实能力的可靠代理。按照 RoboGauge 的指标，作者的架构在所有受评地形上持续优于或达到此前最先进方法的水平。

图内英文对照：Flat：平地；Wave：波浪地形；Slope：斜坡；Stairs：楼梯；Obstacle：障碍地形；Ours：本文方法。

- 我们提出 RoboGauge：一个综合预测性评估框架，利用仿真到仿真方法量化仿真到现实的迁移能力，从而降低直接实机部署导致硬件损坏的风险。
- 我们在策略中加入混合专家模块，解决现有多地形表征能力的不足，并在真实 Unitree Go2 上展示更优的机动能力。
- 我们展示该框架使机器人在平地达到4 m/s，并涌现出与稳定性改善相关的窄幅高速步态。

【重点解释】 原文引言称“4类域随机化”，后文评分使用9种随机化配置；图2实际画了5类地形，而上下坡、上下楼梯拆分后才是7种配置。理解时应区分“因素类别”“测试配置”与“物理地形类别”，这些数量不能直接混用。

II 相关工作

A 四足运动的强化学习

在物理环境中学习四足运动受到严重的样本低效和潜在硬件风险限制[10,45,52]。主流仿真到现实方法使用近端策略优化[42]或教师—学生训练框架，实现速度低于1 m/s的多地形通行[41,24,56]。借助自适应模块进行隐含参数估计、循环信念编码器，以及并行仿真中的对比学习，适应能力进一步提高[23,11,33,36,28]。此外，研究利用指令课程将峰值速度推进到3.9 m/s[31,34]；多种步态[30,35,2]及其无缝切换，则可以从能量优化奖励[8,43,40]和多专家门控架构[53,13]中涌现。

B 仿真到现实评估套件

面向运动模型的评估框架目前仍然有限。相比之下，机器人操作研究已通过排序指标来验证仿真与现实的一致性，以应对类似挑战[26,49]。高保真数字孪生通过环境重建提供闭环评估，但成本通常很高，限制了它们在多样真实场景中的扩展能力[25,58]。

III MoE 隐表征学习

所提出的单阶段强化学习框架以面向四足运动的混合专家隐表征学习为核心，如图1的训练阶段所示。本节首先给出运动控制任务的数学形式和多专家神经网络的内部结构，随后介绍详细的奖励配置和环境配置。

A 强化学习中的运动控制

四足运动控制的核心目标，是根据本体感知，为所有驱动关节确定合适的关节力矩指令。假设本体感知信息完全来自 IMU 和关节编码器，我们将四足运动动力学建模为无限时域的部分可观测马尔可夫决策过程（POMDP），其元组为 $(\mathcal{S},\mathcal{A},\mathcal{O},P,\Omega,R,\rho_0)$。其中，$\mathcal{S}\subset\mathbb{R}^n$ 是包含机器人感知及周围环境全部动力学信息的特权状态空间；$\mathcal{A}\subset\mathbb{R}^m$ 为动作空间；$\mathcal{O}\subset\mathbb{R}^o$ 为观测空间。$P(s'|s,a)$ 描述状态转移概率，$\Omega(o|s)$ 是观测函数，$R(s,a,s')$ 为奖励函数，$\rho_0(s_0)$ 为初始状态分布。目标是学习最优策略 π^*，使轨迹 $\tau=\{s_t,a_t,r_t,s_{t+1},\dots\}$ 上的期望累计折扣奖励最大：

$$J(\pi)=\mathbb{E}_{s_0\sim\rho_0,\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t R(s_t,a_t,s_{t+1})\right] \tag{1}$$

其中，$\gamma\in(0,1)$ 是折扣因子。

令 $o_t\in\mathcal{O}$ 和 $s_t\in\mathcal{S}$ 分别表示时刻 t 的观测与状态。观测包括：IMU 测得的角速度 ω、机身坐标系中的投影重力向量 g_{proj}、关节位置 q 和关节速度 $\dot{q}$、纵向与横向线速度指令 v_x^{cmd} 与 v_y^{cmd}、偏航角速度指令 ω_z^{cmd}，以及前一时刻动作 a_{t-1}。除 o_t 的这些分量外，状态 s_t 还包括线速度 v_t、地形采样高度 h_t，以及表示足部接触力、关节力矩与关节加速度的环境隐含参数 μ_t。高度测量在以机身为中心的1 m×1.6 m矩形区域内按0.1 m间隔采样，以全面表示局部地形。

动作 $a_t\in\mathcal{A}$ 表示相对于初始关节位置的关节位置偏移。模型为每个驱动关节输出目标位置，再由比例—微分（PD）控制器计算所需力矩。

【重点解释】 策略的动作是12个关节的位置偏移，底层 PD 才将位置误差变为力矩。部署观测不含真实机身线速度、局部地形高度或接触力；这些属于训练特权信息。因此“仅本体感知部署”不等于“训练过程完全不使用特权信息”。

B 混合专家表征编码器

为学习最优策略，训练阶段通常使用特权观测 s_t，以加快学习并提高性能上限。由于部署时模型只能获得观测 o_t，教师—学生范式通过蒸馏将有利的策略知识传给学生[24]。并行教师—学生（Concurrent Teacher-Student，CTS）框架[50]同时优化教师和学生网络。在这一并行学习过程中，两者都更新行动者与评论家网络，使学生反馈能够主动改进教师参数。这样的联合优化通常比独立训练获得更好的结果[57]。我们发现，学生模型有限的表达能力，往往使它无法准确推断教师编码的特征，进而限制整体性能上限。为克服这一问题，我们在 CTS 框架的学生架构中引入 MoE 结构[15,17]，增强学生表征能力，并进一步提高整个系统的性能上限。

我们以 MoE 网络替换 CTS 的学生编码器。该架构由 K 个并行专家子网络 $\{E_k\}_{k=1}^{K}$ 构成，各专家专门处理特定指令类型或环境上下文中的观测数据。门控网络 g 根据观测 o_t 动态分配权重 ω_k，协调这些专家。各权重决定对应专家对当前状态表征的相对贡献。因此，学生编码器的隐状态 z_s 是全部专家输出的加权和：

$$z_s=\sum_{k=1}^{K}\omega_k E_k(o_t),\qquad \omega_k=\text{softmax}(g(o_t))_k \tag{2}$$

为避免门控网络只激活单个专家子网络，我们引入辅助负载均衡损失[7,44]：

$$\mathcal{L}_{\text{load balance}}=\sum_{k=1}^{K}\left(\bar{\omega}_k-\tfrac{1}{K}\right)^2,\qquad \bar{\omega}_k=\tfrac{1}{B}\sum_{j=1}^{B}\omega_k^{(j)} \tag{3}$$

其中，B 为训练批量大小，$\omega_k^{(j)}$ 是第 j 个样本分配给第 k 个专家的权重。这一形式鼓励系统在全部专家之间均匀分配任务，以确保表征多样性和表达能力。

【重点解释】 式(2)是在隐特征层混合专家，之后再由行动者产生动作；它没有给出稀疏 top-k 路由，而是对全部专家加权。式(3)只约束“一批样本的平均权重”，不要求每个样本都平均用专家，因此允许专家分工。但平均负载均匀也不能保证专家确实学到了不同能力。

C 奖励设计

多地形模型和平地高速模型采用一致的奖励函数结构。基本奖励配置建立在已有方法[24,41,50]之上，并加入髋关节位置奖励，以减轻高速运动时大腿向外展。附录表 VIII 给出完整奖励规格。其中，σ 是速度跟踪精度参数，初始值为0.25；r^{fr} 沿用 CTS 模型[50]的定义，鼓励高速运动时足部具有足够的离地间隙。对于平地高速训练，我们额外加入髋关节对称性奖励 r^{hs}，在执行纵向直线运动指令时约束关节位置。该项保证机器人维持对称姿态，定义为：

$$r^{\mathrm{hs}} = \frac{|v_x^{\mathrm{cmd}}|}{|v^{\mathrm{cmd}}|_2}\left(|q_{\mathrm{FL}}^{\mathrm{hip}} + q_{\mathrm{FR}}^{\mathrm{hip}}| + |q_{\mathrm{RL}}^{\mathrm{hip}} + q_{\mathrm{RR}}^{\mathrm{hip}}|\right) \tag{4}$$

训练课程包含多种地形，因此一旦机器人形成稳定运动，竖直线速度奖励权重就衰减到零，避免地形起伏导致的竖直速度波动干扰策略优化。我们发现，增大机身高度奖励的权重，可以有效减轻平地高速运动中的机身下沉。多地形模型的参考机身高度设为0.38 m；高速模型则采用更低的0.33 m参考高度，通过降低姿态来改善质心稳定性。

【重点解释】 FL、FR、RL、RR 分别为左前、右前、左后、右后腿。式(4)与表 VIII 的负权重结合后，实际惩罚左右髋关节的不对称；它依赖左右关节的符号约定。原式在零指令时可能出现分母为零，正文未交代保护方式。多地形与高速模型有不同奖励项、权重和参考高度，不能直接理解为同一个已训练策略同时完成全部展示。

D 环境配置

我们使用 IsaacGym 仿真环境[29]，让8192个智能体在多种地形上并行训练。实验平台为具有12个自由度的 Unitree Go2 四足机器人。所有关节的电机 PD 控制增益设为 $k_p = 20.0$、$k_d = 0.5$。控制频率为50 Hz，仿真频率为200 Hz。

合适的课程难度对保证训练表征多样性至关重要。遵循文献[41]，我们构建包含平地、波浪、斜坡、粗糙斜坡、上楼梯、下楼梯和障碍地形的七类地形课程。斜坡倾角从5.7°变化到29.6°，粗糙斜坡叠加5 cm的随机高度起伏。楼梯高度在5 cm至25.7 cm之间，踏面宽度固定为31 cm。障碍地形由随机立方体结构构成，高度范围为5 cm至27.5 cm，宽度范围为1 m至2 m。

为实现有效的仿真到现实迁移，我们引入域随机化，其参数细节见表 I。

表 I 训练域随机化规格

随机化项	范围	单位
摩擦系数	[0.5, 1.5]	无量纲
负载质量	[−1, 1]	kg
连杆质量	[0.9, 1.1]×标称值	kg
机身质心偏移	[−3, 3]×[−3, 3]×[−3, 3]	cm
恢复系数	[0.0, 0.5]	无量纲
比例增益 k_p	[0.9, 1.1]×标称值	N·m/rad
微分增益 k_d	[0.9, 1.1]×标称值	N·m·s/rad
执行器强度	[0.8, 1.2]×标称值	无量纲
执行器偏置	[−0.035, 0.035]	rad
控制延迟	[0, 20]	ms

我们在原始框架[41,36,28,50]中发现了若干训练问题，附录 B 对这些问题及相应消融实验作了详细说明，以验证改进的有效性。为使复杂地形上的奖励更稳定，我们实施动态速度跟踪精度调整（附录 B-A），按地形难度和指令幅值缩放约束。同时，我们加入包含指令课程、极端指令采样和动态指令采样的完整指令设计方案（附录 B-B），保证地形难度能够持续推进。这些策略共同加快收敛，将 RoboGauge 峰值得分提高11%，并促进多样环境中的稳定运动模式。

IV RoboGauge 预测性评估框架

如图1中央评估模块所示，RoboGauge 是连接仿真训练与真实部署的核心评估引擎。本节介绍这一综合框架的设计思路，用于定量验证强化学习运动控制器的性能。

框架基于 MuJoCo 仿真环境[48]构建，工作流程见图3，评估过程分为三个层级：（1）BasePipeline，执行原子化的单环境评估；（2）Multi/Level Pipeline，并行评估难度与域随机化；（3）Stress Pipeline，合成统一的稳健性得分。以下分别介绍定量指标、评估环境和分层评分方法。

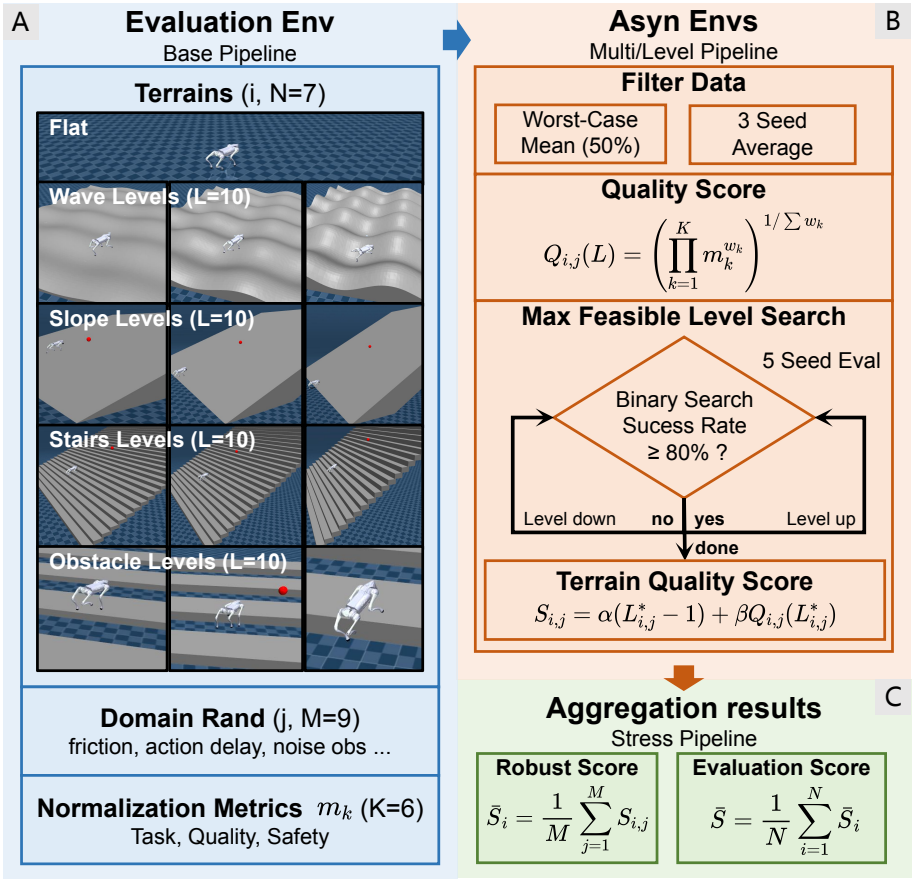


图3 RoboGauge 评估架构包含三个层级。（A）基础流水线：在单个评估环境中组合特定地形与域随机化。（B）多配置/难度流水线：在不同随机种子下并行评估。（C）压力测试流水线：触发对整套地形的全面测试，综合得到最终得分。
图内英文对照：Base Pipeline：基础流水线；Evaluation Env：评估环境；Terrains (N=7)：7种地形配置；Domain Rand (M=9)：9种随机化配置，包括摩擦、动作延迟、观测噪声等；Normalization Metrics (K=6)：6个归一化指标，分为任务、质量、安全；Worst-Case Mean (50%)：最差50%均值；3 Seed Average：3个种子取平均；Filter Data：过滤数据；Quality Score：执行质量分；Max Feasible Level Search：搜索最高可通过等级；Binary Search：二分搜索；5 Seed Eval：5个种子评估；Success Rate ≥80%?：成功率是否至少80%；Level up/down：提高/降低等级；Terrain Quality Score：地形质量分；Aggregation Results：聚合结果；Robust Score/Evaluation Score：稳健分/总评估分。

A 定量性能指标

RoboGauge 的主要目标，是仅依据本体感知反馈得到定量指标，准确反映控制器在真实部署中的有效性。根据实机测试中常见失效模式的经验观察，我们设计了表 II 中的6个指标，覆盖仿真到现实迁移的三个关键方面。首先，为确保硬件安全和效率，评估关节限位和关节功率，避免不良电机运行导致执行器损坏或过热。其次，用速度误差量化跟踪精度，测量控制器执行线速度与角速度指令的准确程度。最后，通过力矩平滑性和姿态稳定性评估运动稳定性，以减轻结构振动并维持稳健的姿态控制。为统一评估，全部原始测量值先归一化，再经过 $f(x)=1-x$ 变换，使更高得分始终代表更好性能。

表 II RoboGauge 框架的指标

指标	说明
线速度误差	线速度的 ℓ_2 跟踪误差
角速度误差	角速度的 ℓ_2 跟踪误差
关节功率	电机功率消耗
关节限位	关节角超出软限位的程度
姿态稳定性	重力在机身横向（y）轴上的投影
力矩平滑性	电机力矩在时间上的平滑程度

【重点解释】6个量先统一成“越大越好”，才能进入后续几何平均。原稿没有给出全部原始指标的计算公式、归一化上下界和截断规则；仅靠表 II 无法精确重建相同得分。另外，实机速度误差验证使用动作捕捉系统提供速度真值，不能理解成所有实机评估都只需 IMU 与编码器。

B 评估环境与随机化

为实现严格而全面的评估，框架构建了一个系统化评估矩阵，整合多种运动目标、复杂地形结构以及广泛的域随机化。

运动目标：我们设计了附录表 VII 所列的运动目标，对控制策略进行压力测试，包括最大幅值指令执行、快速紧急停车，以及对角速度指令的突然阶跃变化。评估还包含由位置误差比例控制器调节的目标位置任务，该任务用作地形通行的通过判据，使框架能够以二分搜索确定模型可通过的最高难度等级。

地形配置：评估套件包含5类不同地形，即平地、波浪、斜坡、楼梯和障碍物。除平地外，每类均划分为10个离散难度等级，以探测控制器机动能力的极限。图3明确展示了第3、5、10级的环境复杂程度。除难度变化外，斜坡与楼梯上的导航还有独特的方向性挑战，因此我们分别评估上行和下行配置，确保不同倾斜方向上的稳健性能。

域随机化：随机化沿环境因素和机器人固有属性两个主要维度展开。环境因素包括负载、摩擦系数等变化；机器人属性包括电机响应延迟、观测噪声。整体上，这些扰动模拟了物理硬件的不完美，防止策略过拟合理想仿真动力学，并保证稳健的实机迁移。

C 分层评分方法

用 $\mathcal{T}=\{T_1,\ldots,T_N\}$ 表示 $N=7$ 种地形配置：将5类地形中的斜坡和楼梯分别拆为上行与下行，作为独立评估环境。对于每一种地形 $T\in\mathcal{T}$，应用 $M=9$ 种不同域随机化配置 $\mathcal{D}=\{d_1,\ldots,d_M\}$。地形难度分为10级，$L\in\{1,2,\ldots,10\}$。每次评估产生 $K=6$ 个性能指标，记为 $\mathcal{M}=\{m_1,\ldots,m_K\}$。

下面形式化说明综合评分方法。对给定地形 T_i、域随机化 d_j 和难度 L，汇总6个归一化指标 $\{m_1,\ldots,m_6\}$；每个 $m_k\in[0,1]$ 是3个随机种子的平均结果。为惩罚性能失衡，特别是避免某个关键维度失效时仍得到高分，使用加权几何平均计算执行质量分：

$$Q_{i,j}(L)=\left(\prod_{k=1}^{K}m_k^{w_k}\right)^{1/\sum_{k=1}^{K}w_k} \tag{5}$$

在不同运动目标上，我们采用最差情况均值（Worst-Case Mean）聚合策略，即在每种目标内对最低50%的得分求平均。这会削弱简单指令产生的高分影响，将评估集中在跨越障碍、步态转换等困难动作上。此外，我们还计算总体均值和最高25%的平均值，作为更全面的参考，详见附录表 XII。

我们采用二分搜索，确定指定域随机化条件下各地形可达到的最大难度 $L_{i,j}^{*}$。对于某一级，用5个随机种子评估模型能否成功到达目标。如果到达目标任务的成功率超过80%，该难度就判定为可通过。

令 $Q_{i,j}(L_{i,j}^{*})$ 表示最高可通过难度上的执行质量分。为平衡不同地形的任务难度与执行质量，针对地形 T_i 和随机化配置 d_j，使用以下重叠评分函数定义地形质量分：

$$S_{i,j}=\alpha(L_{i,j}^{*}-1)+\beta Q_{i,j}(L_{i,j}^{*}) \tag{6}$$

通过设置 $\beta>\alpha$，使较低难度上的高质量表现，能够接近较高难度上的一般表现，从而实现难度层级之间的平滑过渡。

框架结果通过算术平均聚合。首先，在 M 种域随机化上取平均，得到每种地形 T_i 的稳健分 $\bar{S}_i$；然后在全部 N 种地形上取平均，得到最终框架分 $\bar{S}$：

$$\bar{S}_i = \frac{1}{M}\sum_{j=1}^{M} S_{i,j}, \qquad \bar{S} = \frac{1}{N}\sum_{i=1}^{N} \bar{S}_i \tag{7}$$

由于地形类型、随机化参数和随机种子的组合数量很大，完全串行评估耗时过长，因此我们采用多进程加速，并发运行环境实例。这种效率满足了训练阶段快速获得性能反馈的需求。更多实现细节和所有具体超参数见附录 A。

【重点解释】“超过80%”与图3的“≥80%”并不等价：5次试验时，前者要求5/5成功，后者允许4/5。附录 A 又描述以3个种子搜索等级。此处按原文保留差异，复现时需核查代码。二分搜索还默认通过能力大体随难度单调下降；少量随机试验可能破坏这一假设。

V 框架验证与消融研究

本节实验旨在回答以下研究问题：

- Q1：RoboGauge 的指标是否与真实世界性能高度相关？
- Q2：现有最先进方法在这一评估框架下表现如何？
- Q3：混合专家架构能否有效区分不同地形的编码？

A RoboGauge 的指标可靠性

我们将所提出的模型和基线部署到 Unitree Go2 四足机器人上。在机器人机身安装5个标记点，用90 Hz高精度动作捕捉系统，获取平地和10 cm楼梯上的实时线速度与角速度。同时采集本体感知反馈及电机力矩，计算表 II 的6个指标。为量化评估方法的保真程度，将训练环境和本框架得到的指标误差，与真实世界真值进行比较。我们专门评估了一个训练时表现优良、但仿真到现实性能明显下降的模型。

表 III 显示，训练环境持续产生更大的误差。附录表 XI 的完整评分数据进一步确认，相比标准训练评估，本框架的误差显著更低。这表明本框架能更准确反映真实性能，为模型选择提供更可靠的依据。

表 III 指标误差对比（越低越好）

环境	指令	跟踪 ↓	安全 ↓	质量 ↓
MuJoCo（本文）	纵向	0.0573	0.0253	0.0246
MuJoCo（本文）	横向	0.0541	0.0049	0.0079
MuJoCo（本文）	角速度	0.0560	0.0050	0.0035
MuJoCo（本文）	平均	0.0558	0.0117	0.0120
IsaacGym（训练）	纵向	0.1365	0.0844	0.0678
IsaacGym（训练）	横向	0.0572	0.0052	0.0125
IsaacGym（训练）	角速度	0.0713	0.0103	0.0337
IsaacGym（训练）	平均	0.0883	0.0333	0.0380

【重点解释】表 III 支持三类汇总误差下降，但附录表 XI 中，线速度单项平均绝对误差反而是 RoboGauge 的0.0873大于 IsaacGym 的0.0221。因此“所有指标都更准确”超出了表中证据；更合理的理解是汇总评估更接近实机，且各指标存在差异。验证场景也主要是平地和10 cm楼梯，不能直接外推到全部野外地形。

B RoboGauge 下的基线比较

为进行严格比较，我们选择几种仅基于本体感知、采用单阶段训练的先进算法作为基线：

- DreamWaQ[36]：使用非对称行动者—评论家结构，通过变分估计器联合预测机身速度和地形隐变量。
- HIM[28]：引入混合内模型，通过对比学习显式估计机器人的响应。
- CTS[50]：采用非对称教师—学生结构，通过强化学习与监督重构优化智能体。

所有方法使用一致配置，在 IsaacGym[29]中训练8192个并行智能体。由于 DreamWaQ 和 HIM 不支持针对不同地形指定速度指令范围，我们将其最大限制设为1 m/s，并在 RoboGauge 评估中施加相同限制，以降低跟踪难度。相对而言，CTS 和本文模型在训练与评估中均使用2 m/s的指令范围。每种算法使用3个独

立随机种子训练，再选择 RoboGauge 得分最高的模型用于后续分析。表 IV 的结果表明，本文方法在整套指标上显著优于其他方法。

表 IV 基线的 RoboGauge 结果

模型	总分	跟踪 ↑	安全 ↑	质量 ↑	等级
本文	0.67	0.66 ± 0.24	0.78 ± 0.25	0.77 ± 0.25	7.81
CTS	0.58	0.57 ± 0.23	0.70 ± 0.25	0.69 ± 0.25	6.81
HIM	0.53	0.51 ± 0.26	0.63 ± 0.28	0.63 ± 0.28	5.94
DreamWaQ	0.47	0.45 ± 0.27	0.57 ± 0.31	0.56 ± 0.30	5.15

图4的训练曲线表明，与基线相比，本文模型在训练阶段不一定达到最高地形等级，但可预测性评估框架给出的精确评分能够准确反映其内在性能。图5展示了不同摩擦系数下达到的最大地形等级，具体地形等级见附录图15。本文模型在整个摩擦范围内持续表现出更强的地形等级能力。表 VI 的真实部署数据进一步支持这些发现，确认控制器能够在实机上通过此类困难环境。

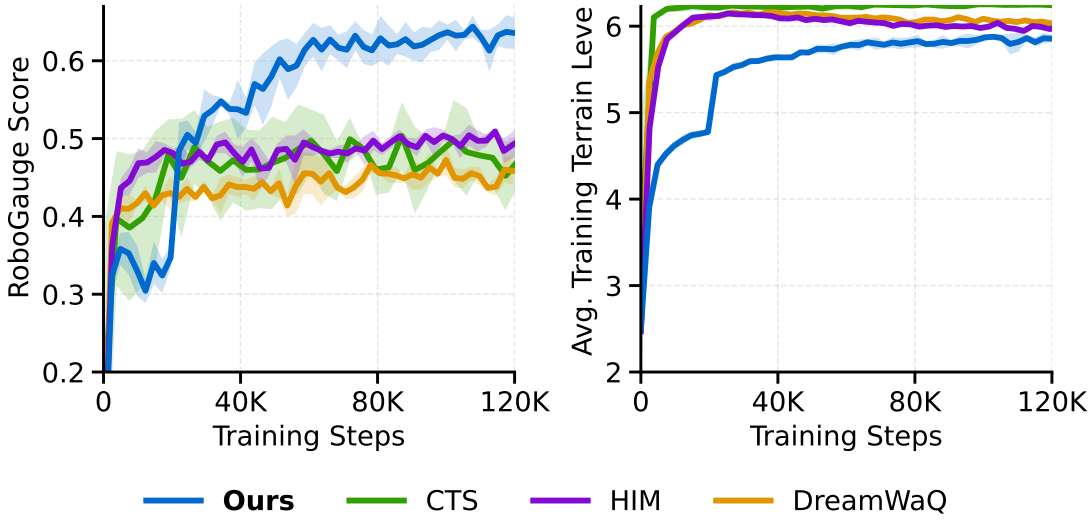


图4 训练过程中，各基线的 RoboGauge 得分与地形等级曲线比较。即使地形等级存在波动，RoboGauge 得分仍相对稳定，说明训练等级不能准确代表模型性能。

图内英文对照：Training Steps：训练步数；RoboGauge Score：RoboGauge 得分；Avg. Training Terrain Level：平均训练地形等级；Ours/CTS/HIM/DreamWaQ：各受评方法。

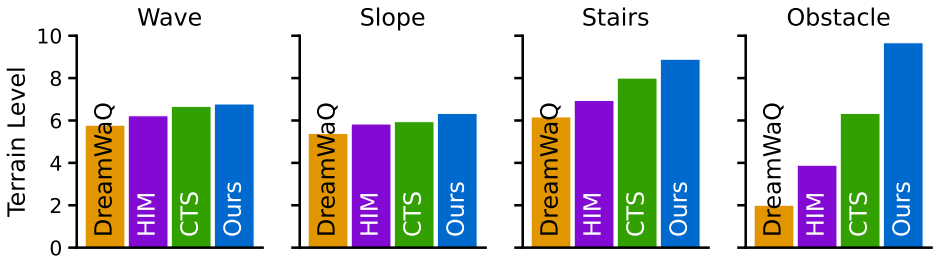


图5 RoboGauge 评估中，不同摩擦系数下最大地形等级的比较。

图内英文对照：Terrain Level：地形等级；Wave/Slope/Stairs/Obstacle：波浪/斜坡/楼梯/障碍；柱上名称表示模型。

【重点解释】比较时各方法的速度指令范围不同，且后续分析选取3个训练种子中得分最高的模型。表 IV 的“±”在原稿中未清晰说明统计单位，因此不能擅自解读为3次独立训练的标准差，也不能仅凭它判断统计显著性。表中优势对应作者这套配置，不能直接推导出各算法在完全同任务设置下的普遍排名。

C MoE 消融与隐表征

我们设计了多种消融实验研究所加入的 MoE 结构，包括：

- MoE-NG：从 MoE 输入中去除指令信息，专家网络仅使用观测信息。

- AC-MoE：遵循 MoE-Loco[13]，将 MoE 应用于行动者—评论家网络，而非学生编码器。
- MCP[39]：对行动者输出的动作采用乘性组合策略。

表 V 表明，本文方法在全部评估指标上获得最佳结果。此外，训练中我们观察到，AC-MoE 和 MCP 等修改动作网络的方法容易出现损失发散。这种不稳定可能源于专家组合直接发生在动作空间。门控网络与各个专家同时自适应，可能产生剧烈波动的控制信号，引发危险动作，并破坏训练稳定性。

表 V MoE 消融的 RoboGauge 结果

模型	总分	跟踪	安全	质量	等级
MoE（本文）	0.6745	0.6574	0.7765	0.7722	7.81
MoE-NG	0.6637	0.6450	0.7651	0.7615	7.67
AC-MoE[13]	0.6589	0.6402	0.7601	0.7538	7.56
MCP[39]	0.6513	0.6343	0.7559	0.7504	7.52

随后使用主成分分析（PCA）[37]，降低学生编码器隐状态的维度，以可视化 MoE 隐空间。图6比较了机器人在多种地形上向前运动5 s时的状态分布，用于评估 MoE 的影响。类似地，附录图17展示了在全部地形上执行前进、后退、左转、右转等不同指令5 s时的隐状态分布。这些结果说明，MoE 架构能更好地区分不同地形与运动指令的编码特征。

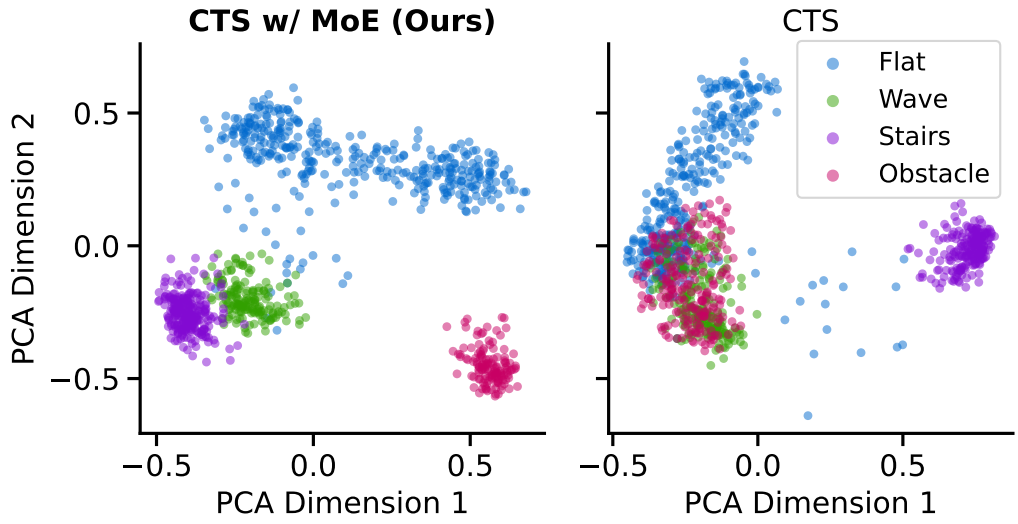


图6 向前指令下，不同地形中学生编码器隐空间的 PCA 可视化。
图内英文对照：左：CTS w/ MoE（本文）；右：CTS；PCA Dimension 1/2：第一/第二主成分；Flat/Wave/Stairs/Obstacle：平地/波浪/楼梯/障碍。

【重点解释】 隐空间分簇说明特征包含可分辨的地形或指令信息，但 PCA 只是低维投影，不能证明每个专家对应一种地形，也不能单凭分簇证明控制性能的因果改善。正文没有报告专家数量、网络层宽及负载均衡系数，复现这些细节需要查看项目代码。

VI 实机部署与泛化

本节真实世界实验旨在回答以下研究问题：

- Q4：与其他基线相比，所提出框架能否在更困难的地形上表现更好？
- Q5：速度指令跟踪有多准确？
- Q6：模型能否在训练未见过的多种复杂环境中可靠运行？

A 困难地形比较

我们将本文模型与基线部署到 Unitree Go2 上，评估实机性能，结果见表 VI。验证包括三种稳健性场景：80—100 N的突然横向拉力、15.5 cm的光滑瓷砖楼梯，以及30 cm障碍物攀爬；附录图18展示具体装置。只有本文模型成功越过30 cm障碍，并在横向拉拽时表现出最有效的扰动抑制。虽然本文方法与内置强化学习控制器都能通过楼梯，但本文模型通过85级台阶所需时间比基线少17 s。

表 VI 真实世界存活率比较（原表以成功数/总数呈现）

模型	横向拉力 80—100 N	15.5 cm瓷砖楼梯 摩擦系数0.38	30 cm障碍物 摩擦系数0.85
本文	18/20	85/85	17/20
内置强化学习	5/20	85/85	0/20
CTS	11/20	18/85	0/20
HIM	8/20	24/85	0/20
DreamWaQ	7/20	12/85	0/20

【重点解释】原表标题写“存活率（%）”，实际列的是次数比或台阶比。18/20为90%，17/20为85%；85/85结合正文是85级台阶，不能当作85次独立完整楼梯试验。原文将短时拉力称为 impulse，但 N 是力的单位，冲量单位应为 N·s；未给拉力持续时间就无法算真实冲量。

B 速度跟踪精度

我们用动作捕捉系统评估平地和楼梯场景下的速度跟踪精度。图7中，机器人通过楼梯的平均速度为1.31 m/s，跟踪误差为0.15 m/s，说明该框架即使在复杂环境中也有较强的跟踪能力。我们还在30°木质斜坡上评估运动性能，机器人保持1.53 m/s的平均速度，相比内置强化学习基线缩短1.7 s，相关结果见图8（原文称“附录图8”，该图实际位于正文）。

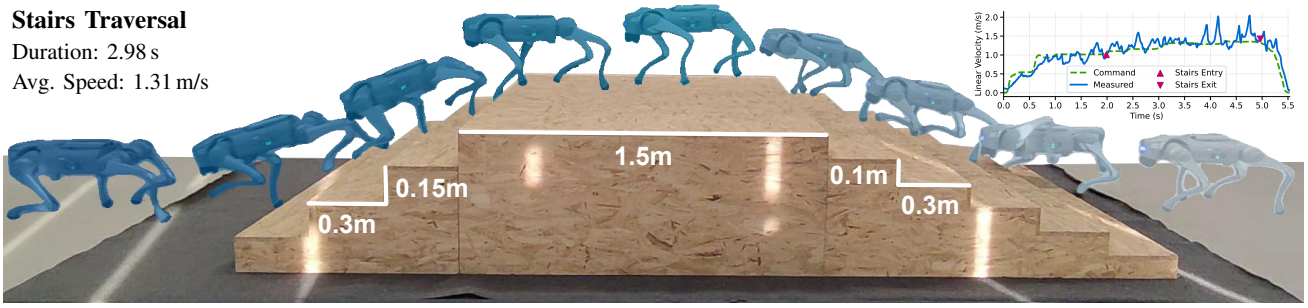


图7 上台阶高度10 cm、下台阶落差15 cm的木质楼梯实验。右上方曲线为动作捕捉系统记录的速度跟踪，误差为0.15 m/s。

图内英文对照：Stairs Traversal：楼梯通行；Duration：用时2.98 s；Avg. Speed：平均速度1.31 m/s；Time：时间；Linear Velocity：线速度；Command/Measured：指令/实测；Stairs Entry/Exit：进入/离开楼梯。场景其他标注尺寸：0.3 m、1.5 m、0.3 m。

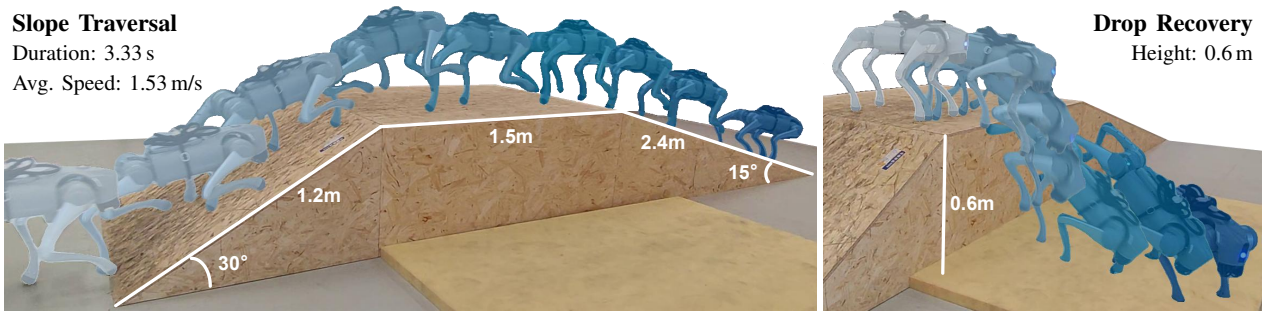


图8 斜坡通行与下落恢复中的稳健运动。左图：在摩擦系数0.55的斜坡上，相比内置强化学习基线节省1.7 s。右图：从60 cm高度跌落后可靠恢复。

图内英文对照：Slope Traversal：斜坡通行，用时3.33 s，平均速度1.53 m/s；斜坡标注30°、15°，长度标注1.2 m、1.5 m、2.4 m；Drop Recovery：下落恢复；Height：高度0.6 m。

图9展示平地高速运动的跟踪性能。受室内8 m跑道限制，机器人在2.16 s内达到4.01 m/s峰值，跟踪误差0.20 m/s，展现出出色的加速与制动能力。值得注意的是，即便没有显式运动约束，模型仍自主形成稳定的窄支撑步态，以减小质心的侧向摆动并增强高速运动稳定性。

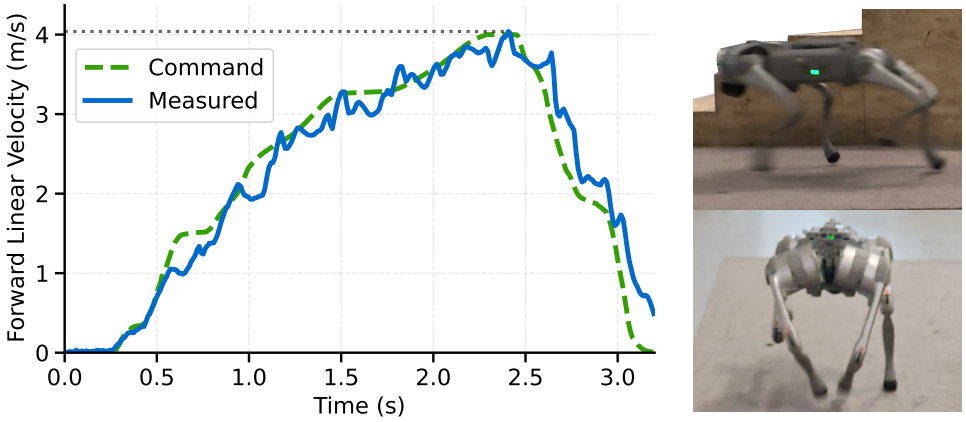


图9 在摩擦系数0.6的表面上进行速度跟踪和步态测试。左图显示机器人在2.16 s内达到4.01 m/s，误差0.20 m/s。右上图捕捉到短暂腾空阶段，右下图展示稳定的窄支撑步态。

图内英文对照：Forward Linear Velocity：前向线速度；Time：时间；Command：指令；Measured：实测。

【重点解释】这里的4.01 m/s是8 m室内跑道中的短时峰值，不能直接当作持续巡航速度。作者称窄步态“无显式运动约束”，但训练确实加入髋关节位置和对称性奖励。较准确的理解是没有给定完整步态轨迹或脚点模板，而奖励仍对腿部姿态施加了偏好。

C 稳定性与泛化

我们在两种困难实机场景中验证紧急恢复能力。首先，机器人受到强烈推、拉等外力时，通过调整质心和生成抵消冲击的步态，展现出较强的扰动抑制能力。图10和图18表明，在25—40 N持续横向拉力和85—100 N突然拉力下，机器人仍保持稳定，而既有基线几乎都无法保持平衡。其次，当机器人突然失去支撑时，它会快速重构步态，重新获得落脚支撑，防止向前翻倒。图8展示从60 cm落差恢复的成功序列；图14则展示机器人从平地意外跌落到楼梯时，如何自然转换为稳定姿态。

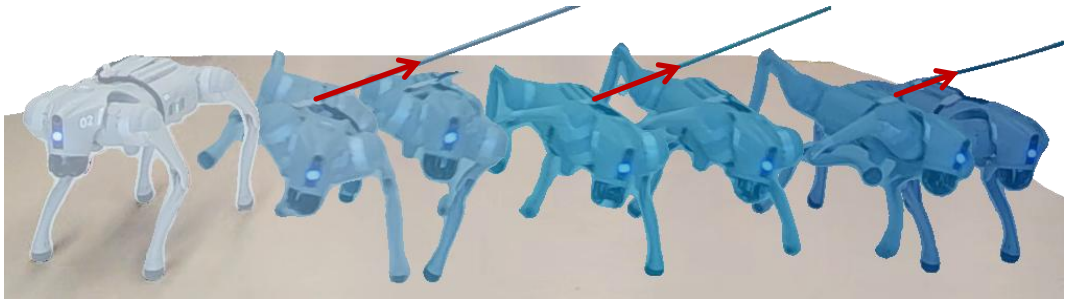


图10 平地上的持续横向拉力抗扰实验。机器人承受约25—40 N的反复横向拉拽，同时维持稳定运动。

图内英文对照：红色箭头表示外部横向拉力方向。

最后，我们在多种室外环境开展实地测试，评估框架的泛化能力。图1右侧展示机器人在沙地、冰面、斜坡和不平地面等环境中的表现。机器人以100%的成功率完成全部试验，且没有意外终止，凸显所学策略出色的稳健性。

VII 结论与未来工作

本文提出一种由 RoboGauge 评估套件和 MoE 运动策略构成的训练框架，使机器人仅依赖本体感知即可实现稳健的多地形运动。Unitree Go2 实机实验表明，该框架成功克服了30 cm障碍物和100 N短时拉力等困难条件，同时在平地上使用相同训练配置达到4.01 m/s峰值速度。框架在跟踪精度和恢复稳定性方面持续优于已有基线，并在多样室外实地测试中获得100%成功率。预测性评估与模块化架构的协同，为弥合仿真结果与物理实际表现之间的差距提供了可靠、高效的途径。

未来研究将把 RoboGauge 扩展到人形机器人等更广泛的形态，并将外部感知融入 MoE 表征，以进一步提高跨越复杂结构地形的能力。

【重点解释】“100%成功率”是作者在所做室外测试中的观察结果；原稿没有列出这些场景各自的试验次数、路线长度和失败判据，因此不能转化为开放环境中的总体成功概率。结论中的“相同训练配置”也需要结合前文多地形/高速模型的奖励和高度差异理解。

附录 A RoboGauge 补充材料

A 实现细节

各流水线的运行逻辑如下。BasePipeline 协调仿真引擎 sim、负责控制指令与指标计算的评估器 gauge，以及运动模型 robot 之间的交互。此外，它还管理异常处理、域随机化和观测噪声的施加。

MultiPipeline 利用多进程，在不同随机种子和域随机化配置下执行 BasePipeline，并汇总输出文件。为确定给定地形可通行的最高难度，LevelPipeline 寻找模型在3个独立随机种子下都能成功通过的最高等级。

在式(5)的质量分计算中，任务完成指标的权重设为 $w_k = 2$，其他指标设为 $w_k = 1$。式(6)的重叠评分函数使用超参数 $\alpha = 0.09$、$\beta = 0.19$，保证性能分数位于 $[0, 1]$。

表 VII 运动控制目标配置

目标名称	说明	重置条件	最多试次
最大速度	评估单一维度的峰值线速度或角速度	每个方向指令后突然停车	6
对角速度	跟踪耦合的对角速度向量（组合线速度和角速度）	每对对角指令完成后	8
目标位置速度	使用比例控制器按位置误差跟踪并到达目标	到达目标或超出时间限制	1

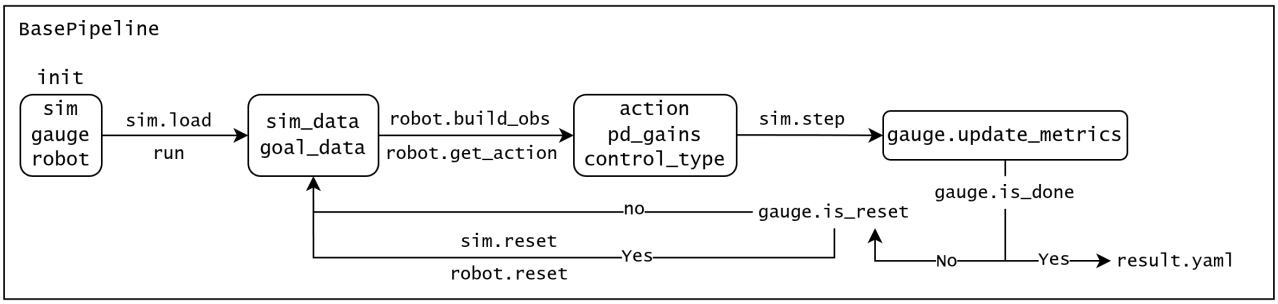


图11 BasePipeline 的运行流程。
图内英文对照：init：初始化 sim（仿真器）、gauge（评估器）、robot（策略模型）；sim.load/run：加载仿真并运行；sim_data/goal_data：仿真数据/目标数据；robot.build_obs/get_action：构造观测/求动作；action/pd_gains/control_type：动作/PD增益/控制类型；sim.step：仿真步进；gauge.update_metrics：更新指标；gauge.is_done：判断是否完成；gauge.is_reset：判断是否重置；sim.reset/robot.reset：重置仿真/模型；Yes/No：是/否；result.yaml：保存结果文件。

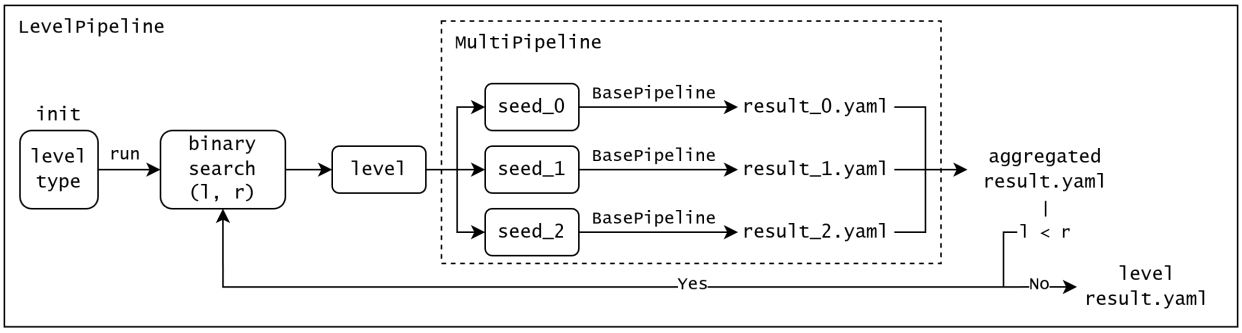


图12 LevelPipeline 的运行流程。
图内英文对照：init level/type：初始化等级范围与地形类型；binary search (l,r)：在左右边界间二分搜索；level：待评等级；MultiPipeline：多配置并行流水线；seed_0/1/2：3个随机种子；各自运行 BasePipeline 并输出 result_0/1/2.yaml；aggregated result.yaml：合并结果；l<r：判断左右界是否仍未相遇；Yes：继续搜索；No：输出等级结果 level result.yaml。

【重点解释】 附录 A 给出了评分权重和两层流水线逻辑，但没有列齐9个评估随机化配置、指标归一化阈值或全部地形等级尺寸。因此它足以帮助理解架构，尚不足以独立复现所有数值。图11、12的函数名是代码接口标识，保留英文并逐项给出中文含义。

附录 B 训练细节

A 动态速度跟踪精度调整

为使速度跟踪精度 σ 适应地形特征与难度等级，我们实现动态缩放调整。我们发现，当最大指令范围由0.5扩大到1.5时，在波浪、楼梯和障碍等困难地形上，机器人往往无法准确跟踪线速度指令。因此，对跟踪系数进行缩放，在这些场景中放宽跟踪约束。

设 $[v_{\min}, v_{\max}]$ 为动态调整 σ 所用的速度幅值范围，$\sigma_{\max}^{T_i}$ 表示分配给第 i 类地形的最大速度跟踪系数。给定该地形上的指令速度 v，中间系数 σ_{vel} 定义如下（原文左侧未单独写出变量名，以下为便于阅读补上）：

$$\sigma_{\text{vel}} = \begin{cases} \sigma, & v \in [0, v_{\min}), \\ \sigma(v - v_{\min}) + \sigma_{\max}^{T_i}(v_{\max} - v), & v \in [v_{\min}, v_{\max}), \\ \sigma_{\max}^{T_i}, & v \in [v_{\max}, \infty). \end{cases} \tag{8}$$

最终自适应跟踪系数 σ_{now} 纳入地形难度等级 L，定义为：

$$\sigma_{\text{now}} = \sigma + \min(e^{L/10} - 1, 1)(\sigma_{\text{vel}} - \sigma) \tag{9}$$

速度指令 v 同时涵盖纵向、横向线速度指令，以及角速度指令。附录表 IX 列出了不同地形的最大速度跟踪系数 $\sigma_{\max}^{T_i}$ 及对应的速度调整范围。

【重点解释】 这里存在两处需要核对的公式疑点。第一，式(8)中段缺少通常线性插值中的区间长度归一化，而且两端权重方向与上下段不衔接：表 IX 的调整区间长度都为1，在 v=v_min 时中段得到最大系数，在接近 v_max 时却回到初始系数。第二，表 VIII 写的是 exp(−σe²)，增大 σ 会使跟踪更严格，而文字称要“放宽”。若使用 exp(−e²/σ)才会有相反效果。译稿照录原式，不能未经代码确认就选一种解释当作作者实现。

B 指令设计

在全部地形上直接使用完整的 $[-1, 1]$ m/s指令范围训练，能够快速推进难度等级，但常产生不稳定步态。具体而言，机器人可能出现跳跃、高频摆腿等不规则行为。相反，从低速指令开始，有利于形成稳定运动模式。因此我们引入表 X 所示的指令课程。

我们发现，当最大指令幅值超过 $[-1, 1]$ m/s时，机器人在波浪、楼梯和障碍等复杂地形上无法准确跟踪目标线速度。这种跟踪偏差会导致训练不稳定。因此，我们按地形分别限制最大指令范围，详见表 IX。值得注意的是，这些限制在训练时严格执行，而真实机器人测试时不施加同样限制。尽管存在这种差异，模型仍能跟踪超出训练分布的指令，体现出稳健的泛化能力。

经验分析表明，均匀采样分布并非最优：边界值的出现概率极低，但实机部署却经常使用它们。为此，我们引入极端指令采样策略。该方法分配10%的概率给静止指令，20%的概率给三个维度都取最大速度边界的指令组合。此外，当线速度为零时，保留20%的概率采样最大角速度，以增强原地转向的稳健性。

训练初始阶段，线速度指令限制在 $[-0.5, 0.5]$ m/s内，并有10%的概率保持静止。这样的窄分布常会生成无法满足地形升级条件的指令序列：升级要求相对初始位置的最终水平位移超过4 m，即地形长度的一半[41]。这会阻碍智能体探索更高难度。因此，我们采用动态指令采样，以保证累计指令长度超过所需阈值。

令 n_r 为已经采样的指令数量，v_i^{cmd} 为第 i 个线速度指令，T_r 为采样间隔，T_{ep} 为回合时长。第 n_r+1 个指令的采样范围限制在 $(v_{\min}, -v^*) \cup (v^*, v_{\max})$ 内，其中：

$$v^* := \text{clip}\left(\frac{5 - |\sum_{i=1}^{n_r} v_i^{\text{cmd}}|_2 T_r}{T_{\text{ep}} - n_r T_r},\ 0,\ \min(|v_{\min}|, |v_{\max}|) \right) \tag{10}$$

如果第 n_r+1 次采样选择了静止指令，其具体持续时间按下式决定：

$$T^{\text{zero}} = \text{clip}\left(T_{\text{ep}} - n_r T_r - \frac{5 - |\sum_{i=1}^{n_r} v_i^{\text{cmd}}|_2 T_r}{0.8 \max(v_x^{\max}, v_y^{\max})},\ 0,\ T_r \right) \tag{11}$$

综合上述指令课程、极端指令采样和动态指令采样，可以在保证地形难度稳步推进的同时，促进更稳定步态的形成。此外，这些策略显著提高了模型在 RoboGauge 中的性能上限。

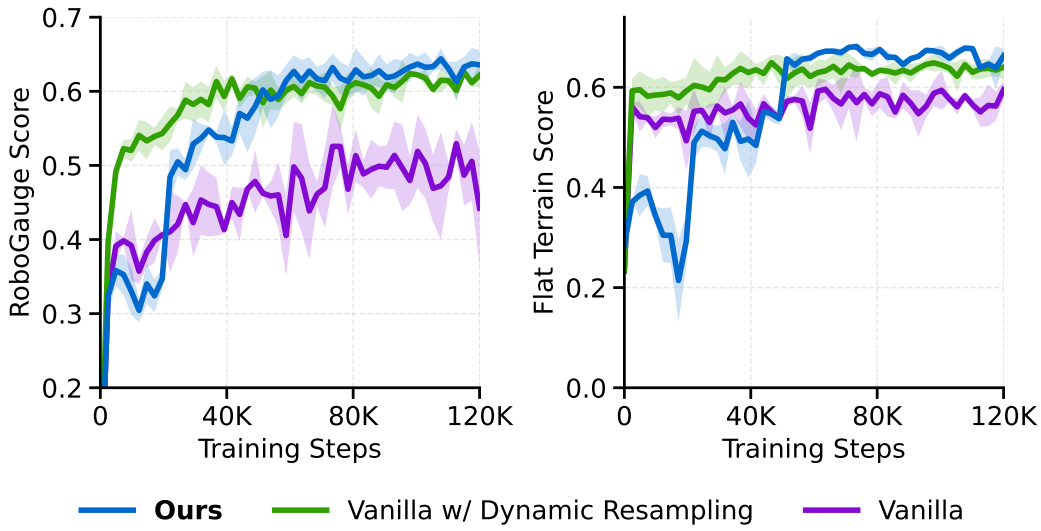


图13 训练策略消融研究。

图内英文对照：Training Steps：训练步数；RoboGauge Score：总评估分；Flat Terrain Score：平地得分；Ours：全部改进；Vanilla w/ Dynamic Resampling：基础方案加动态重采样；Vanilla：基础方案。

我们对训练配置进行了消融研究，图13展示动态指令采样的影响。启用该功能，相比不使用动态采样的版本，能加快收敛并使峰值奖励提高11%。最终训练曲线则进一步加入动态速度跟踪精度调整和指令课程。这些改进显著增强了训练稳定性，并提高平地性能。

【重点解释】式(10)、(11)中的常数5表示期望覆盖距离的余量，正文升级阈值则为4 m。式中使用“指令向量之和的模”，接近净位移预算，不是总路程；反向指令会互相抵消，而且真实速度未必等于指令速度。所以这些采样规则可提高升级机会，并不能严格保证最终真实位移一定越过阈值。原文此处称“峰值奖励”，图13纵轴实际为 RoboGauge 得分。

附录 C 训练配置

表 VIII 奖励函数规格

奖励项	表达式	多地形权重	平地高速权重
线速度跟踪	$\exp(-\sigma\lvert v_{xy}^{\mathrm{cmd}}-v_{xy}\rvert_2^2)$	1.0	2.0
角速度跟踪	$\exp(-\sigma\lvert\omega_z^{\mathrm{cmd}}-\omega_z\rvert^2)$	0.5	0.5
竖直线速度	v_z^2	−2.0	−2.0
横滚/俯仰角速度	$\lvert\omega_{xy}\rvert_2^2$	−0.05	−0.05
关节加速度	$\ddot{q}^2$	-2.5×10^{-7}	-2.5×10^{-7}
关节功率	$\lvert\tau\rvert\lvert\dot{q}\rvert^T$	-2×10^{-5}	-2×10^{-5}
关节力矩	$\lvert\tau\rvert_2^2$	-1×10^{-4}	-1×10^{-4}
机身高度	$(h^{\mathrm{des}}-h)^2$	−1.0	−1.0
动作变化率	$\lvert a_t-a_{t-1}\rvert_2^2$	−0.01	−0.01
动作平滑性	$\lvert a_t-2a_{t-1}+a_{t-2}\rvert_2^2$	−0.01	−0.01
碰撞	$n^{\mathrm{collision}}$	−1.0	−1.0
关节限位	$n^{\mathrm{limitation}}$	−2.0	−2.0
足部调节	r^{fr}	−0.05	−0.05
髋关节调节	$\lvert q^{\mathrm{hip}}-q^{\mathrm{hip}}_{\mathrm{default}}\rvert$	−0.05	−0.05
髋关节对称性	r^{hs}	不使用	−1

原表以黑色表示多地形模型的奖励项，以红色表示平地高速模型改动的权重。本译表将颜色差异展开为两列：红色变动仅为线速度跟踪权重2.0及新增髋关节对称项−1；其他格沿用原表。正文另说明竖直线速度权重训练后衰减至0，以及机身高度权重调整，但没有在表中列出完整时间表或调整后的全部数值。

表 IX 各地形最大速度跟踪系数与指令限制

地形	$\sigma^i_{\max}$	v_x (m/s)	v_y (m/s)	ω_z (rad/s)
平地	1/4	±2.0	±1.0	±2.0
波浪	5/12	±1.5	±1.0	±1.5
斜坡	1/4	±1.5	±1.0	±1.5
上楼梯	1/2	±1.0	±1.0	±1.5
下楼梯	1/2	±1.0	±1.0	±1.5
障碍	3/4	±1.0	±1.0	±1.5

表 IX 原注：速度调整范围定义为线速度幅值 $v_{\text{lin}} \in [0.5, 1.5]$ m/s，角速度幅值 $v_{\text{ang}} \in [1.0, 2.0]$ rad/s。这里的调整范围用于式(8)，不要与各地形允许采样的最大指令范围混为一谈。

表 X 指令课程阶段与速度限制

阶段	训练步数	v_x (m/s)	v_y (m/s)	ω_z (rad/s)
初始	$[0, 2\times10^4]$	±0.5	±0.5	±1.0
中间	$[2\times10^4, 5\times10^4]$	±1.0	±1.0	±1.5
高级	$[5\times10^4, \infty]$	±2.0	±1.0	±2.0

附录 D 补充实验

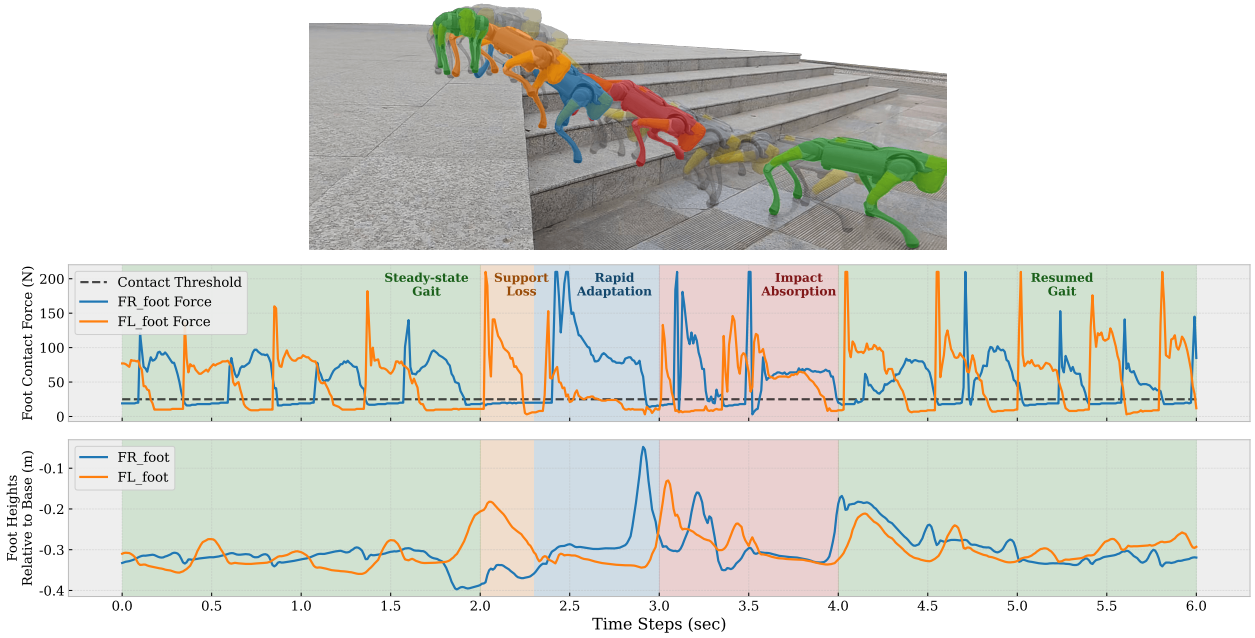


图14 上方序列展示地面在边缘突然终止时，机器人快速调整姿态、安全下到楼梯的过程。中间曲线为足部传感器测得的接触力信号，下方曲线为通过正运动学计算的前足相对机身高度。结果验证了策略的稳健性，以及应对多种挑战时自适应转换步态的能力。

图内英文对照：Foot Contact Force：足接触力（N）；Contact Threshold：接触阈值；FR/FL foot Force：右前/左前足接触力；Steady-state Gait：稳态步态；Support Loss：支撑丢失；Rapid Adaptation：快速适应；Impact Absorption：吸收冲击；Resumed Gait：恢复步态；Foot Heights Relative to Base：相对机身的足高度（m）；Time Steps (sec)：时间（s）。

【重点解释】图14使用足部传感器记录接触力作为分析证据，不表示这些测量输入了部署策略。仅凭本体感知的策略能够对已经发生的接触变化作出反应；它并没有因此获得在接触之前看见楼梯边缘的能力。

表 XI（1/5）完整评估：实机测量（真值）

运动	线速度跟踪	角速度跟踪	关节功率	关节限位	姿态稳定	力矩平滑
纵向 x=1	0.9185	0.5808	0.8527	0.9159	0.9675	0.7739
横向 y=0.5	0.9552	0.7037	0.9696	0.9384	0.9661	0.8985
偏航 z=1	0.9552	0.8010	0.9659	0.9439	0.9614	0.9020
楼梯 x=1	0.8554	0.2732	0.6721	0.8395	0.8749	0.5944

表 XI（2/5）完整评估：RoboGauge 预测

运动	线速度跟踪	角速度跟踪	关节功率	关节限位	姿态稳定	力矩平滑
纵向 x=1	0.8217	0.5669	0.8330	0.9386	0.9592	0.7853
横向 y=0.5	0.8685	0.6822	0.9704	0.9293	0.9627	0.8861
偏航 z=1	0.8763	0.7679	0.9734	0.9414	0.9647	0.8983
楼梯 x=1	0.7596	0.2507	0.6211	0.8472	0.8625	0.6606

表 XI（3/5）完整评估：RoboGauge 绝对误差 ↓

运动	线速度跟踪	角速度跟踪	关节功率	关节限位	姿态稳定	力矩平滑
x=1合并	0.0963	0.0182	0.0354	0.0152	0.0103	0.0388
平均	0.0873	0.0243	0.0145	0.0089	0.0057	0.0183

表 XI（4/5）完整评估：IsaacGym 预测

运动	线速度跟踪	角速度跟踪	关节功率	关节限位	姿态稳定	力矩平滑
纵向 x=1	0.8977	0.7826	0.9155	0.9361	0.9737	0.8289
横向 y=0.5	0.9694	0.8039	0.9598	0.9378	0.9707	0.8781
偏航 z=1	0.9853	0.9134	0.9751	0.9325	0.9798	0.9510
楼梯 x=1	0.8786	0.5732	0.8635	0.9027	0.9339	0.7454

表 XI（5/5）完整评估：IsaacGym 绝对误差 ↓

运动	线速度跟踪	角速度跟踪	关节功率	关节限位	姿态稳定	力矩平滑
x=1合并	0.0220	0.2509	0.1271	0.0417	0.0326	0.1030
平均	0.0221	0.1545	0.0487	0.0179	0.0185	0.0575

表 XI 的数值为归一化评分或相应绝对误差，并非速度、瓦特等原始物理量。线速度指令单位为 m/s，偏航角速度为 rad/s。“x=1 合并”保留原表 Merge 标识：其数值对应纵向与楼梯两场景的合并误差。平均行按原表保留。

表 XII（1/3）基线的详细指标：角速度误差与线速度误差

模型	角速度误差 mean	mean@25	mean@50	线速度误差 mean	mean@25	mean@50
本文	0.66	0.6241	0.6402	0.6919	0.6561	0.6746
CTS	0.5777	0.5369	0.5554	0.6005	0.5527	0.5774
HIM	0.5098	0.4644	0.4857	0.5551	0.5148	0.5355
DreamWaQ	0.4522	0.4092	0.4288	0.4954	0.4548	0.4755

表 XII（2/3）基线的详细指标：关节限位与关节功率

模型	关节限位 mean	mean@25	mean@50	关节功率 mean	mean@25	mean@50
本文	0.8057	0.8006	0.803	0.7633	0.7382	0.75
CTS	0.7269	0.7218	0.7241	0.6857	0.6604	0.6723
HIM	0.6574	0.6517	0.6538	0.6201	0.6008	0.6095
DreamWaQ	0.5953	0.5899	0.5919	0.5611	0.5426	0.5512

表 XII（3/3）基线的详细指标：姿态稳定性与力矩平滑性

模型	姿态稳定性 mean	mean@25	mean@50	力矩平滑性 mean	mean@25	mean@50
本文	0.8036	0.7986	0.8009	0.7546	0.736	0.7435
CTS	0.7237	0.7165	0.72	0.6777	0.6585	0.6666
HIM	0.6541	0.6439	0.6493	0.6135	0.5975	0.6038
DreamWaQ	0.5929	0.5835	0.5884	0.5508	0.5354	0.5415

表 XII 保留原表列名 mean（总体均值）、mean@25、mean@50。虽然前两类指标名中含“误差”，此处已经按评分流程转为越高越好。正文把 mean@50 对应最差50%，同时称报告“最高25%均值”；但表中 mean@25 普遍低于 mean，二者口径不一致。未核查代码前，不把 mean@25 擅自改名为最高或最低25%。

表 XIII（1/4）基线的详细地形得分：平地、波浪

模型	平地 mean	mean@25	mean@50	波浪 mean	mean@25	mean@50
本文	0.7851	0.586	0.6885	0.6344	0.5569	0.5961
CTS	0.7454	0.4846	0.6211	0.6183	0.5389	0.5765
HIM	0.7719	0.523	0.6536	0.579	0.4975	0.5338
DreamWaQ	0.7706	0.528	0.6547	0.5401	0.4629	0.497

表 XIII（2/4）基线的详细地形得分：斜坡前向、斜坡后向

模型	斜坡前向 mean	mean@25	mean@50	斜坡后向 mean	mean@25	mean@50
本文	0.5896	0.5175	0.5536	0.5916	0.5205	0.5562
CTS	0.5629	0.4905	0.5227	0.5377	0.4655	0.5001
HIM	0.5087	0.4334	0.4689	0.5842	0.5086	0.547
DreamWaQ	0.408	0.3421	0.3734	0.6081	0.5411	0.5753

表 XIII（3/4）基线的详细地形得分：楼梯前向、楼梯后向

模型	楼梯前向 mean	mean@25	mean@50	楼梯后向 mean	mean@25	mean@50
本文	0.8102	0.7246	0.7578	0.7958	0.7103	0.7472
CTS	0.8106	0.7309	0.7561	0.6185	0.5373	0.568
HIM	0.4654	0.38	0.4125	0.7972	0.7153	0.7475
DreamWaQ	0.3742	0.2991	0.3274	0.7419	0.6608	0.6916

表 XIII（4/4）基线的详细地形得分：障碍

模型	障碍 mean	mean@25	mean@50
本文	0.8737	0.7858	0.8219
CTS	0.5785	0.4907	0.5289
HIM	0.3646	0.2876	0.3227
DreamWaQ	0.206	0.1243	0.1645

表 XIII 的 forward/backward 依原表译为前向/后向；正文则以升/降方向描述斜坡和楼梯配置，复现时应确认机器人朝向与地形方向的对应。表中并非每个单项均为本文最优，例如楼梯前向 mean 的 CTS 为0.8106，本文为0.8102；楼梯后向 mean 的 HIM 为0.7972，本文为0.7958。

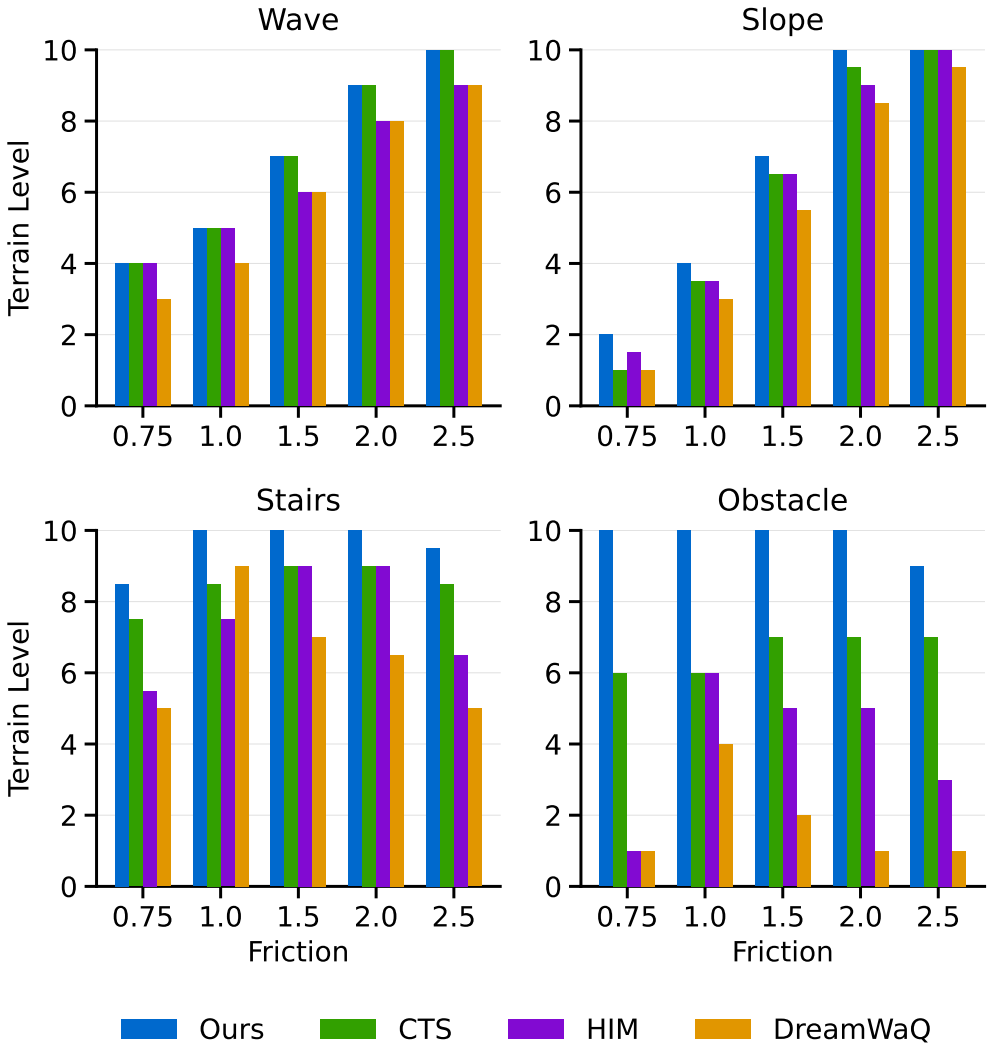
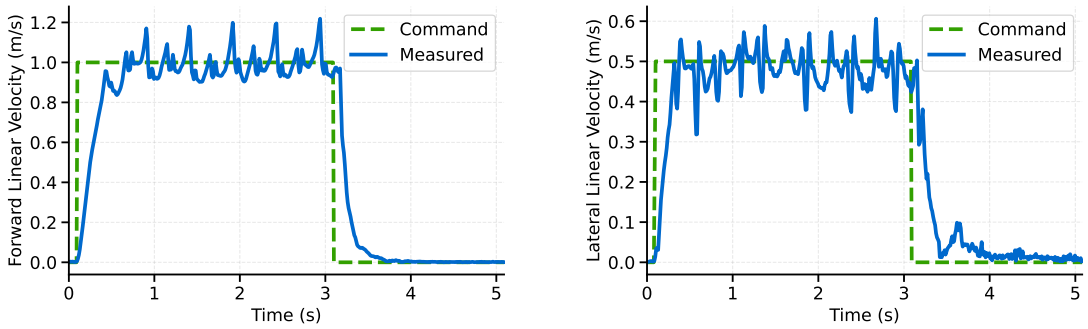


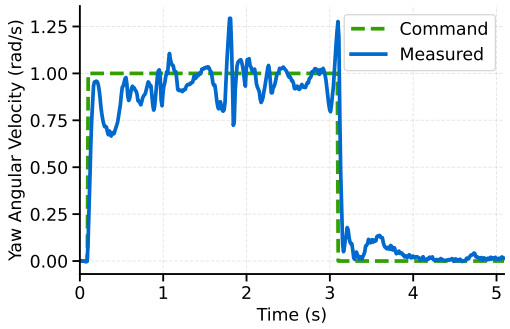
图15 不同模型在部分摩擦系数条件下达到的最高地形难度。图注说明摩擦范围为0.5—2.5，步长0.25；实际图中展示的横轴标签为0.75、1.0、1.5、2.0、2.5。

图内英文对照：Wave/Slope/Stairs/Obstacle：波浪/斜坡/楼梯/障碍；Terrain Level：地形等级；Friction：摩擦系数；Ours/CTS/HIM/DreamWaQ：各模型。

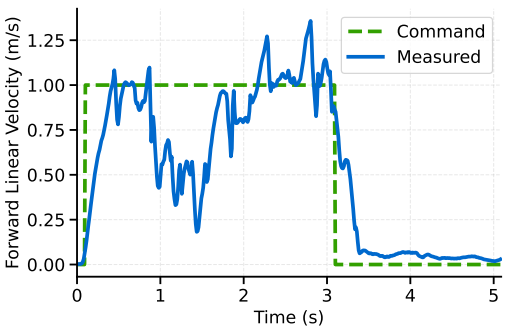


(a) With $v_x^{\text{cmd}} = 1.0$ m/s

(b) With $v_y^{\text{cmd}} = 0.5$ m/s



(c) With $\omega_z^{\text{cmd}} = 1.0$ rad/s



(d) 10 cm stairs with $v_x = 1.0$ m/s

图16 原图注说明：绿色虚线为90 Hz动作捕捉系统测得的速度真值，蓝色实线为预设评估程序自动发送给 Unitree Go2 的目标指令。子图分别为：（a）前向1.0 m/s；（b）横向0.5 m/s；（c）偏航1.0 rad/s；（d）10 cm楼梯、前向1.0 m/s。

图内英文对照：Command：指令；Measured：实测；Time：时间；Forward/Lateral Linear Velocity：前向/横向线速度；Yaw Angular Velocity：偏航角速度。注意：图中图例实际把绿色虚线标为 Command、蓝色实线标为 Measured，与原图注的线色描述相反；此处明确保留这一差异。

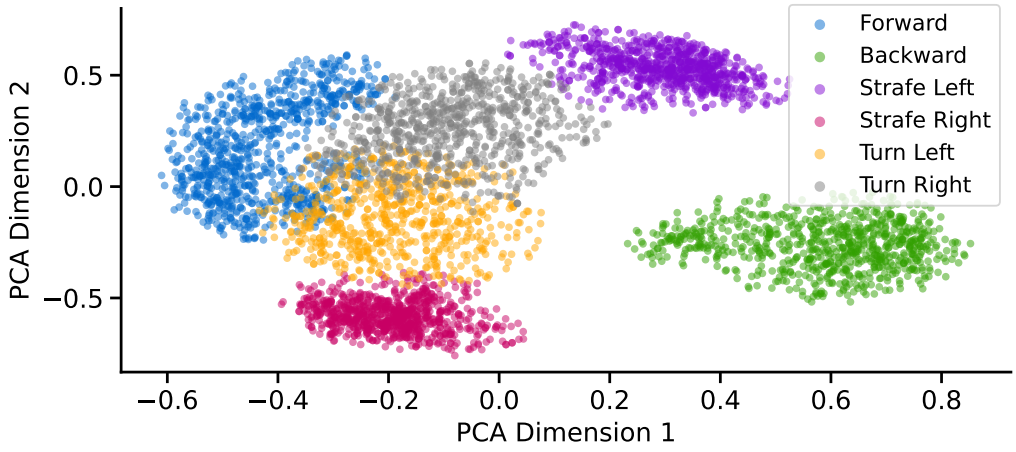


图17 在全部地形上、不同指令下的学生编码器隐空间 PCA 可视化。

图内英文对照：Forward/Backward：前进/后退；Strafe Left/Right：左移/右移；Turn Left/Right：左转/右转；PCA Dimension 1/2：第一/第二主成分。

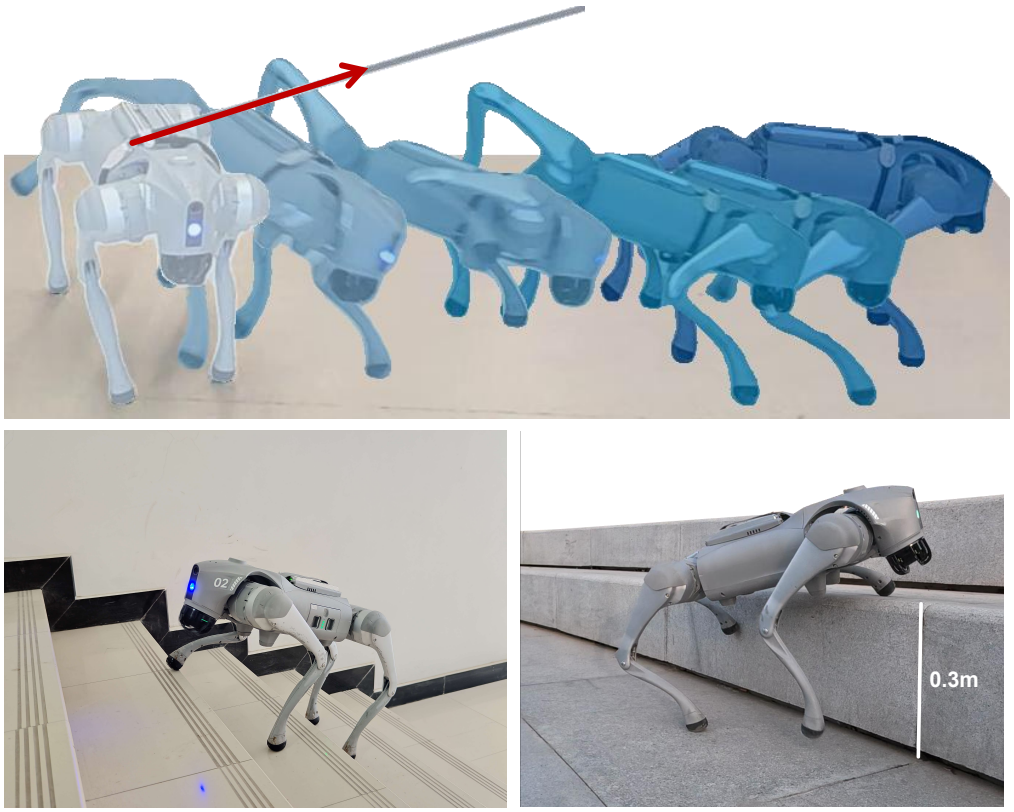


图18 Unitree Go2 在三种困难场景中的运动性能。上图：抵抗80—100 N横向短时拉力并保持平衡。左下：稳定爬升15.5 cm瓷砖楼梯，摩擦系数0.38。右下：成功通过30 cm障碍，摩擦系数0.85。
图内英文对照：0.3 m：障碍高度30 cm；红色箭头表示拉拽方向。

译者附加：从论文主线到工程复现的深入解读

以下20节为译者的教学性解读、推导与工程建议，不属于原文实验结果。阅读时建议先看第1—4节建立主线，再结合第8—11节理解评分，最后用第17—20节整理复现工作。没有自测题或答案环节。

1 先抓住问题：奖励高，为什么还不能上实机？

训练奖励衡量的是“策略在训练仿真器、训练指令分布和奖励权重下做得怎样”。实机迁移则还取决于接触模型、惯量误差、延迟、噪声以及此前没遇到的地形。策略可能学会利用训练引擎中的接触细节，获得很高奖励，但这些细节换到真实硬件后就不存在了。训练地形等级也只是课程中的进度指标，不能覆盖全部控制质量。

这篇论文把问题拆成两个环节：第一，用 MoE 增强学生编码器的表达能力，减少多地形、多指令共享一个紧凑表征时的冲突；第二，让候选策略进入另一个仿真器和一组标准化压力测试，再决定是否部署。图4的重要性在于提示你：模型选择标准会影响最终得到的实机策略，不能只盯训练奖励曲线。

2 把整套系统连起来：训练—评估—选择—部署

训练端在 IsaacGym 中让8192个 Go2 并行采样。教师借助特权状态学习较强表征，学生根据机载可获取的信息学习对应表征；本文在 CTS 的学生编码器中放入 MoE。部署时保留学生侧所需的编码器、门控、专家和行动者，不把地形高度真值传到实机。策略输出关节目标偏移，底层 PD 实现关节控制。

评估端将训练好的策略放进 MuJoCo，在不同地形、难度、运动目标、随机化和种子下运行，得到执行质量分、可通过等级及最终总分。这个分数用于选择模型，也可反馈到指令课程、随机化和奖励设计。所谓“闭环”主要是开发和选模流程闭环；论文并没有给出一个用 RoboGauge 分数自动端到端反向传播训练策略的算法。

3 本体感知究竟知道什么，不知道什么？

IMU 给出角速度和姿态相关信息，编码器给出关节位置、速度，上一时刻动作告诉模型自己刚做了什么，速度指令告诉它现在要做什么。按正文列出的分量，常见拼接维度可计算为3+3+12+12+3+12=45；这是根据列举变量的维数推算，原稿没有明确报告最终实现是否还堆叠历史或采用额外预处理。

同一个瞬时关节姿态可能对应平地、踩上台阶或即将滑动等不同外部状态，因此任务部分可观测。仅本体感知通常要从身体受到地形作用后的响应中推断上下文，属于接触后的适应，不能自动解决接触前的视觉规划问题。部署观测限制、教师特权信息和评估真值来源，是三件需要分别检查的事。

4 MoE 放在隐空间里，究竟改变了什么？

普通编码器把各种地形和指令都压缩进同一套参数。MoE 则让多个子网络分别提取候选特征，由门控网络按当前观测和指令决定它们的比例。假设三个专家输出分别为 z_1, z_2, z_3，门控给出0.7、0.2、0.1，那么学生隐变量就是 $0.7z_1 + 0.2z_2 + 0.1z_3$。这些向量是供控制使用的特征，不一定分别等于“楼梯高度”“摩擦系数”“速度真值”。

所有专家加权后才进入行动者，相当于先组合对局面的描述，再统一决定动作。若把多个专家的动作直接混合或乘性组合，专家与门控同步变化时可能直接使电机目标剧烈变化。论文的消融支持在当前训练设置下隐空间混合表现更好，但“动作层 MoE 必然不稳定”并不是一般定理。

5 负载均衡为什么不妨碍专家分工？

式(3)先对一批样本求各专家的平均门控权重，再要求这些平均值接近 $1/K$。例如4个专家，每个样本都只偏向某一个专家，只要这一批样本覆盖四种情形且数量大致均衡，平均负载仍可接近四分之一。因而批级均衡允许样本级专门化。

如果全部样本都只用第一个专家，平均权重为(1,0,0,0)，损失为 $(1-1/4)^2+3(0-1/4)^2=0.75$；若平均为(1/4,1/4,1/4,1/4)，损失为0。但所有专家输出完全一样时，负载均衡也可能是0。检查专家是否有用，还应观察专家输出差异、门控随工况的变化，以及去掉专家后的性能变化，而不能只看这一损失。

6 指令为什么也要进入编码器？

相同地形下，“慢速爬楼梯”和“快速前进”需要不同的身体姿态、脚部摆动和稳定性取舍。如果编码器不看指令，它要生成一种同时适合所有动作目标的表征，再让下游行动者补偿任务差异；让指令直接参与编码，可以提前形成面向当前目标的上下文。

表 V 中，去掉 MoE 指令输入后，总分从0.6745降到0.6637，绝对差0.0108。这个消融说明指令条件化有帮助，但差距比“完全换掉基线方法”的差距小。原稿没有给出消融跨训练种子的误差条，不宜把小数点后每个差异都解释为稳定可重复的改进。

7 窄步态与髋关节奖励：把“涌现”读准确

髋关节调节项惩罚关节偏离默认位置，抑制过度外展；对称项惩罚左右髋关节角之和的绝对值。当左右关节的正方向定义相反时，镜像对称姿态对应两者之和接近零。前置比例 $|v_x^{\mathrm{cmd}}|/|v^{\mathrm{cmd}}|_2$ 使这一偏好更侧重纵向指令。若机型的关节轴定义改变，直接照搬加号就可能奖励错误姿态。

窄支撑减少侧向摆动可能有利于高速效率，但也缩小横向静态支撑宽度，是否稳定取决于动态落脚、接触时序和速度。论文展示的是高速模型学到了这样的步态，不能推出“腿越靠拢越稳定”。它没有提供完整脚点模板，但奖励已经对髋关节姿态施加了引导，这两点可以同时成立。

8 6个指标分别在防什么问题？

线速度和角速度跟踪误差衡量任务执行：机器人跑得稳但不听指令，也不能算好策略。关节限位关注越过软范围的风险；功率指标关注电机负担；姿态横向重力投影反映侧倾倾向；力矩平滑性反映高频控制波动。这些量互补，因此论文不只用一个成功率。

同时，各指标都只是代理。机械功率低不等于电机温升低，静止大力矩也可能发热；横向重力投影小不能独自覆盖俯仰倾倒、足滑和全局翻滚；平滑力矩也可能来自动作过于迟缓。学习时应把指标理解成特定失效模式的观测窗口，而不是完整的安全性定义。原稿缺少归一化细节，复现时应先把这些计算口径对齐。

9 几何平均为什么比算术平均更怕短板？

设6个指标中两个跟踪指标权重各为2，其余四个各为1，总权重为8。若所有指标都为0.8，则几何平均也是0.8。若一个跟踪指标降到0.1，其他五项仍为0.8，则执行质量分为 $(0.1^2\times0.8^6)^{1/8}\approx0.476$；同样权重下的算术平均则为0.625。几何平均会更强地惩罚关键维度的短板。

只要某个正权重指标为0，整个几何平均就为0。实现中是否对指标加小正数、怎样处理 NaN、失效和缺失观测，都会影响最终评分。原稿没有给这些细节，不应默认为某个常见实现。对于正数指标，可以在对数域计算加权均值以减轻数值下溢；这是工程建议，并非论文已报告的实现。

10 为什么把难度和质量一起算？

只比较同一简单地形上的跟踪分，可能把一个上不了高台但走得很平稳的策略排得很高；只比较最高等级，则可能偏爱勉强冲过去、动作危险的策略。式(6)把“能够做到多难”与“在这个难度做得多好”结合起来。每提高一级增加0.09，质量项最多贡献0.19，因此相邻等级之间存在重叠区间。

例如，等级5、执行质量0.9时，$S=0.09\times4+0.19\times0.9=0.531$；等级6、质量0.4时，$S=0.09\times5+0.19\times0.4=0.526$。较低等级上的高质量表现可以略胜较高等级上的一般表现。在等级10且质量为1时，得分恰为1；等级1且质量为1时仅为0.19。平地不分10级时如何放入这一公式，原稿没有完整解释，不能自行指定等级。

11 最差50%与总体平均，各自保留和掩盖什么？

在指令或时间样本上只看平均值，容易让长时间轻松行走掩盖转向、起停或越障瞬间的失稳。取最低50%的分数均值，会把注意力转向较难的那部分表现。它和“每一时刻都必须通过安全约束”不同，也和取单个最坏值不同，属于稳健性与噪声敏感性之间的折中。

不过，最后式(7)又在随机化和地形上做算术平均，所以局部失效仍可能被其他条件的高分补偿。例如7类地形中6类得0.8、一类为0，平均仍约0.686。工程选择时可同时报告最低地形分和失败次数。mean@25 的正文描述与表格数值存在冲突，阅读时保留原列名，等确认代码中的排序方向、聚合样本和先后顺序后再解释。

12 二分搜索最高等级：快在哪里，风险在哪里？

对10个等级逐一评估最多需10次等级测试；若通过/失败随难度单调，二分搜索通常只需约4次。每次等级测试又要跑多个种子，因此节省会被放大。可是机器人策略可能在某一台阶高度触发特定节律，在更高一级反而偶然通过；随机扰动也可能使同一级结果不稳定。

正文的5种子以及“>80%”意味着必须5次全成功；图3的“≥80%”则允许4次成功；附录又写3种子都成功。这些差异会改变最高等级和评分。复现应先确认实际判据，并记录每一级每个种子的二元结果；必要时在搜索边界附近多测相邻等级。5次全成功本身也不足以证明真实成功概率接近100%。

13 IsaacGym→MuJoCo 为什么可能更接近现实？

在不同物理引擎中运行，同一策略必须面对不同的接触求解、摩擦处理和数值积分行为。能同时适应两套仿真动力学的策略，可能较少依赖训练引擎的偶然特性，从而更有机会迁移到真实机器人。这是一种跨模型压力测试，而不是 MuJoCo 自动具有真实世界全部物理现象。

两个仿真器也可能共享同一个错误的机器人质量、惯量、关节轴或传感器预处理；软沙、积雪和复杂足底接触也未必被准确建模。因此 sim-to-sim 是风险筛查的一层，实机仍需验证。论文以表 III 和 XI 支持预测误差改善，但没有建立跨多机器人、多任务的大规模迁移概率模型。项目页也将其描述为“部分预测”实机表现。

14 表 III 和 XI 应该怎样一起读？

表 III 把误差归并为跟踪、安全、质量三类，RoboGauge 的均值均低于训练环境：0.0558对0.0883、0.0117对0.0333、0.0120对0.0380。这支持其汇总评估更接近实机，但表 XI 把指标拆开后，线速度误差是明显例外。RoboGauge 线速度得分整体偏低，训练仿真在这个单项上反而更接近实测。

对于一个筛选工具，除了绝对预测误差，还关心它能否把不同策略的实机优劣排序正确。如果所有策略都被低估同样幅度，排序仍可能有用；反之，总均值很接近也可能把两个候选排反。若扩展这项工作，可在多个模型、多个检查点和实机场景上同时报告误差、排序相关和高风险误选率。这是进一步验证建议，原文没有报告这些统计量。

15 基线比较的优势在哪里，边界在哪里？

本文总分0.67高于 CTS 的0.58、HIM 的0.53和 DreamWaQ 的0.47，实机30 cm障碍的17/20也构成直观证据。但 DreamWaQ/HIM 使用1 m/s上限，CTS/本文使用2 m/s，这会同时改变任务难度、训练分布和运动能力上限。降低评估指令有利于跟踪，却也可能影响越障动量，不能简单说比较一定偏向某一边。

此外，每种方法选3个训练种子中的最佳模型，得到的是“训练后择优部署”的表现，不是随机训练一次的期望表现。附录表 XIII 还有基线在某些方向上的略高单项。因此应把结论读作“本文配置在作者综合评估和实机测试中具有优势”，并把算法本体、训练课程、指令范围、奖励改进和选模规则的贡献分别考虑。

16 动态跟踪精度：先看公式的单调性

常见跟踪奖励有两种写法：$r=\exp(-e^2/\sigma)$ 与 $r=\exp(-\sigma e^2)$。对同样的非零误差，第一种增大 σ 会提高奖励，第二种增大 σ 会降低奖励。论文表 VIII 使用第二种，却把困难地形上的更大 σ 解释为放宽约束。因此工程上最先要核对的，是代码实际把参数放在分子还是分母。

若只讨论数学上通常的连续插值，可令 $u=(v-v_{\min})/(v_{\max}-v_{\min})$，再用 $(1-u)\sigma+u\sigma_{\max}^{T_i}$ 连接两端。这是译者给出的合理插值示例，不是原式(8)，也未证明作者实现采用它。式(9)中的难度因子在 $L\geq 10\ln 2\approx 6.93$ 时已经饱和为1，所以7级及以上不再继续增强这一调整。

17 指令课程为什么会改变地形课程？

指令课程控制“让机器人学多快、转多猛”，地形课程控制“让机器人面对多难的地面”。两者通过位移升级判据耦合：当低速、静止和相反方向指令让净位移不足时，即使当前控制很稳定，也可能无法升级地形。于是策略一直停留在简单环境，得不到更复杂的接触经验。动态采样试图留出足够的剩余运动预算，缓解这个问题。

极端采样则补上均匀分布很少覆盖的边界情况，如最大转向、最大复合指令和停车。实施时应检查三个概率的条件关系：静止10%、全维极端20%、零线速度时最大角速度20%不能机械相加为一个互斥分布。原稿没有完整交代抽样分支顺序和剩余概率的分配，这些细节需要代码确认。

18 复现时先检查哪些接口？

第一批检查应围绕动作闭环：关节编号与腿序、关节正方向、默认姿态、动作尺度、限位、PD 增益及力矩饱和。第二批检查观测闭环：坐标系定义、IMU 角速度单位、重力投影方向、编码器零位、速度滤波、指令归一化和上一时刻动作的含义。跨引擎模型若在这些接口上不一致，会把软件映射错误伪装成策略泛化不足。

论文的50 Hz策略周期为20 ms，200 Hz仿真步长为5 ms，对应每4个物理步更新一次动作；原文没有单独说明底层 PD 在每个仿真步的具体执行逻辑，应以实现为准。控制延迟随机范围0—20 ms，已可达到一个策略周期。真实部署应实测传感器采集、推理、通信和驱动更新各段延迟，而不是只测神经网络前向计算时间。

19 把论文还缺的参数整理成复现清单

网络方面，需要确认专家数量、各网络层宽、隐变量维度、门控温度或其他路由设置，以及负载均衡损失权重。训练方面，需要确认 PPO 超参数、教师学生损失的组合、观测历史、动作缩放、梯度裁剪，以及奖励权重衰减时间表。论文没有列出的参数，不能借用 CTS 的默认值后就声称与本文完全一致。

评估方面，需要确认6个指标的原始表达式、归一化区间、异常和失败处理、9个随机化配置、10级地形的尺寸、平地评分方式、种子数、80%判据以及 mean@25 的定义。对表 VIII、式(8)的跟踪参数方向疑点，要保留原文与实际代码的逐项对照，最后在实验记录里说明采用的版本和差异。

20 怎样用这篇论文建立自己的学习框架？

先用图1画出信息流：哪些量来自实机传感器，哪些只在训练时有，哪些只用于评估。再用式(2)、(3)理解“表征怎样形成”，用式(5)—(7)理解“策略怎样被选中”，用表 VI 和图7—10理解“选出的策略在物理世界做到了什么”。这样可以把网络、评价和真实证据分开，再看它们如何互相支撑。

之后把表 V 当作理解架构选择的证据，把图13和附录 B 当作理解训练分布设计的证据，把表 XI 当作检查预测能力边界的证据。对你做机器狗运动控制最实用的启发是：策略结构、训练数据分布和部署前评价共同决定结果。一个更复杂的编码器有价值，但能发现失败模式、对齐接口并可靠选择模型的评估流程，同样是运动控制系统的重要组成部分。

参考文献

[1] OpenAI: Marcin Andrychowicz, Bowen Baker, Maciek Chociej, Rafal Jozefowicz, Bob McGrew, Jakub Pachocki, Arthur Petron, Matthias Plappert, Glenn Powell, Alex Ray, et al. Learning dexterous in-hand manipulation. The International Journal of Robotics Research, 39 (1):3–20, 2020.

[2] Guillaume Bellegarda, Milad Shafiee, and Auke Ijspeert. Allgaits: Learning all quadruped gaits and transitions. In 2025 IEEE International Conference on Robotics and Automation (ICRA), pages 15929–15935. IEEE, 2025.

[3] Russell Buchanan, Lorenz Wellhausen, Marko Bjelonic, Tirthankar Bandyopadhyay, Navinda Kottege, and Marco Hutter. Perceptive whole-body planning for multilegged robots in confined spaces. Journal of Field Robotics, 38 (1):68–84, 2021.

[4] Yevgen Chebotar, Ankur Handa, Viktor Makoviychuk, Miles Macklin, Jan Issac, Nathan Ratliff, and Dieter Fox. Closing the sim-to-real loop: Adapting simulation randomization with real world experience. In 2019 International Conference on Robotics and Automation (ICRA), pages 8973–8979. IEEE, 2019.

[5] Jia-Ruei Chiu, Jean-Pierre Sleiman, Mayank Mittal, Farbod Farshidian, and Marco Hutter. A collision-free mpc for whole-body dynamic locomotion and manipulation. In 2022 international conference on robotics and automation (ICRA), pages 4686–4693. IEEE, 2022.

[6] Thomas Dudzik, Matthew Chignoli, Gerardo Bledt, Bryan Lim, Adam Miller, Donghyun Kim, and Sangbae Kim. Robust autonomous navigation of a small-scale quadruped robot in real-world environments. In 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 3664–3671. IEEE, 2020.

[7] William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. Journal of Machine Learning Research, 23(120):1–39, 2022.

[8] Zipeng Fu, Ashish Kumar, Jitendra Malik, and Deepak Pathak. Minimizing energy consumption leads to the emergence of gaits in legged robots. In Conference on Robot Learning, pages 928–937. PMLR, 2022.

[9] Magnus Gaertner, Marko Bjelonic, Farbod Farshidian, and Marco Hutter. Collision-free mpc for legged robots in static and dynamic scenes. In 2021 IEEE International Conference on Robotics and Automation (ICRA), pages 8266–8272. IEEE, 2021.

[10] Sehoon Ha, Peng Xu, Zhenyu Tan, Sergey Levine, and Jie Tan. Learning to walk in the real world with minimal human effort. In Conference on Robot Learning, pages 1110–1120. PMLR, 2021.

[11] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. Neural Computation, 9(8):1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.

[12] David Hoeller, Lorenz Wellhausen, Farbod Farshidian, and Marco Hutter. Learning a state representation and navigation in cluttered and dynamic environments. IEEE Robotics and Automation Letters, 6(3):5081–5088, 2021.

[13] Runhan Huang, Shaoting Zhu, and Yilun Du. Moe-loco: Mixture of experts for multitask locomotion. In 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 14218–14225, 10 2025. doi: 10.1109/IROS60139.2025.11246585.

[14] Jemin Hwangbo, Joonho Lee, Alexey Dosovitskiy, Dario Bellicoso, Vassilios Tsounis, Vladlen Koltun, and Marco Hutter. Learning agile and dynamic motor skills for legged robots. Science Robotics, 4(26):eaau5872, 2019.

[15] Robert A Jacobs, Michael I Jordan, Steven J Nowlan, and Geoffrey E Hinton. Adaptive mixtures of local experts. Neural computation, 3(1):79–87, 1991.

[16] Gwanghyeon Ji, Juhyeok Mun, Hyeongjun Kim, and Jemin Hwangbo. Concurrent training of a control policy and a state estimator for dynamic and robust legged locomotion. IEEE Robotics and Automation Letters, 7 (2):4630–4637, 2022.

[17] Michael I Jordan and Robert A Jacobs. Hierarchical mixtures of experts and the em algorithm. Neural computation, 6(2):181–214, 1994.

[18] Sertac Karaman and Emilio Frazzoli. Sampling-based algorithms for optimal motion planning. The international journal of robotics research, 30(7):846–894, 2011.

[19] Oussama Khatib. Real-time obstacle avoidance for manipulators and mobile robots. The international journal of robotics research, 5(1):90–98, 1986.

[20] Donghyun Kim, Daniel Carballo, Jared Di Carlo, Benjamin Katz, Gerardo Bledt, Bryan Lim, and Sangbae Kim. Vision aided dynamic exploration of unstructured terrain with a small-scale quadruped robot. In 2020 IEEE International Conference on Robotics and Automation (ICRA), pages 2464–2470. IEEE, 2020.

[21] Yunho Kim, Hyunsik Oh, Jeonghyun Lee, Jinhyeok Choi, Gwanghyeon Ji, Moonkyu Jung, Donghoon Youm, and Jemin Hwangbo. Not only rewards but also constraints: Applications on legged robot locomotion. IEEE Transactions on Robotics, 40:2984–3003, 2024.

[22] Sylvain Koos, Jean-Baptiste Mouret, and Stéphane Doncieux. The transferability approach: Crossing the reality gap in evolutionary robotics. IEEE Transactions on Evolutionary Computation, 17(1):122–145, 2012.

[23] Ashish Kumar, Zipeng Fu, Deepak Pathak, and Jitendra Malik. Rma: Rapid motor adaptation for legged robots. Robotics: Science and Systems XVII, 2021.

[24] Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning quadrupedal locomotion over challenging terrain. Science robotics, 5 (47):eabc5986, 2020.

[25] Xinhai Li, Jialin Li, Ziheng Zhang, Rui Zhang, Fan Jia, Tiancai Wang, Haoqiang Fan, Kuo-Kun Tseng, and Ruiping Wang. Robogsim: A real2sim2real robotic gaussian splatting simulator. arXiv preprint arXiv:2411.11839, 2024.

[26] Xuanlin Li, Kyle Hsu, Jiayuan Gu, Karl Pertsch, Oier Mees, Homer Rich Walke, Chuyuan Fu, Ishikaa Lunawat, Isabel Sieh, Sean Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. In RSS 2024 Workshop: Data Generation for Robotics.

[27] Qiayuan Liao, Zhongyu Li, Akshay Thirugnanam, Jun Zeng, and Koushil Sreenath. Walking in narrow spaces: Safety-critical locomotion control for quadrupedal robots with duality-based optimization. In 2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 2723–2730. IEEE, 2023.

[28] Junfeng Long, Zirui Wang, Quanyi Li, Liu Cao, Jiawei Gao, and Jiangmiao Pang. Hybrid internal model: Learning agile legged locomotion with simulated robot response. In ICLR, 2024.

[29] Viktor Makoviychuk, Lukasz Wawrzyniak, Yunrong Guo, Michelle Lu, Kier Storey, Miles Macklin, David Hoeller, Nikita Rudin, Arthur Allshire, Ankur Handa, et al. Isaac gym: High performance gpu based physics simulation for robot learning. In NeurIPS Datasets and Benchmarks, 2021.

[30] Gabriel B Margolis and Pulkit Agrawal. Walk these ways: Tuning robot control for generalization with multiplicity of behavior. In Conference on Robot Learning, pages 22–31. PMLR, 2023.

[31] Gabriel B Margolis, Ge Yang, Kartik Paigwar, Tao Chen, and Pulkit Agrawal. Rapid locomotion via reinforcement learning. In Robotics: Science and Systems, 2022.

[32] Matias Mattamala, Nived Chebrolu, and Maurice Fallon. An efficient locally reactive controller for safe navigation in visual teach and repeat missions. IEEE Robotics and Automation Letters, 7(2):2353–2360, 2022.

[33] Takahiro Miki, Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. Science robotics, 7(62):eabk2822, 2022.

[34] Prakhar Mishra, Amir Hossain Raj, Xuesu Xiao, and Dinesh Manocha. Hacl: History-aware curriculum learning for fast locomotion. arXiv preprint arXiv:2505.18429, 2025.

[35] Alexander Luis Mitchell, Wolfgang Merkt, Aristotelis Papatheodorou, Ioannis Havoutis, and Ingmar Posner. Gaitor: Learning a unified representation across gaits for real-world quadruped locomotion. In 8th Annual Conference on Robot Learning, 2024.

[36] I Made Aswin Nahrendra, Byeongho Yu, and Hyun Myung. Dreamwaq: Learning robust quadrupedal locomotion with implicit terrain imagination via deep reinforcement learning. In 2023 IEEE International Conference on Robotics and Automation (ICRA), pages 5078–5084. IEEE, 2023.

[37] Karl Pearson. Liii. on lines and planes of closest fit to systems of points in space. The London, Edinburgh, and Dublin philosophical magazine and journal of science, 2 (11):559–572, 1901.

[38] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In 2018 IEEE international conference on robotics and automation (ICRA), pages 3803–3810. IEEE, 2018.

[39] Xue Bin Peng, Michael Chang, Grace Zhang, Pieter Abbeel, and Sergey Levine. Mcp: Learning composable hierarchical control with multiplicative compositional policies. Advances in neural information processing systems, 32, 2019.

[40] Skand Peri, Akhil Perincherry, Bikram Pandit, and Stefan Lee. Non-conflicting energy minimization in reinforcement learning based robot control. In 9th Annual Conference on Robot Learning, 2025.

[41] Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning. In Conference on robot learning, pages 91–100. PMLR, 2022.

[42] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017.

[43] Milad Shafiee, Guillaume Bellegarda, and Auke Ijspeert. Viability leads to the emergence of gait transitions in learning agile quadrupedal locomotion on challenging terrains. Nature Communications, 15(1):3073, 2024.

[44] Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarz, Andy Davis, Quoc Le, Geoffrey Hinton, and Jeff Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. arXiv preprint arXiv:1701.06538, 2017.

[45] Laura Smith, J Chase Kew, Xue Bin Peng, Sehoon Ha, Jie Tan, and Sergey Levine. Legged robots that keep on learning: Fine-tuning locomotion policies in the real world. In 2022 international conference on robotics and automation (ICRA), pages 1593–1599. IEEE, 2022.

[46] Zhi Su, Xiaoyu Huang, Daniel Ordoñez-Apraez, Yunfei Li, Zhongyu Li, Qiayuan Liao, Giulio Turrisi, Massimiliano Pontil, Claudio Semini, Yi Wu, et al. Leveraging symmetry in rl-based legged locomotion control. In 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 6899–6906. IEEE, 2024.

[47] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In 2017 IEEE/RSJ international conference on intelligent robots and systems (IROS), pages 23–30. IEEE, 2017.

[48] Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems, pages 5026–5033, 2012. doi: 10.1109/IROS.2012.6386109.

[49] Wei-Cheng Tseng, Jinwei Gu, Qinsheng Zhang, Hanzi Mao, Ming-Yu Liu, Florian Shkurti, and Lin Yen-Chen. Scalable policy evaluation with video world models. arXiv preprint arXiv:2511.11520, 2025.

[50] Hongxi Wang, Haoxiang Luo, Wei Zhang, and Hua Chen. Cts: Concurrent teacher-student reinforcement learning for legged locomotion. IEEE Robotics and Automation Letters, 2024.

[51] Jinze Wu, Guiyang Xin, Chenkun Qi, and Yufei Xue. Learning robust and agile legged locomotion using adversarial motion priors. IEEE Robotics and Automation Letters, 8(8):4975–4982, 2023.

[52] Philipp Wu, Alejandro Escontrela, Danijar Hafner, Pieter Abbeel, and Ken Goldberg. Daydreamer: World models for physical robot learning. In Conference on robot learning, pages 2226–2240. PMLR, 2023.

[53] Chuanyu Yang, Kai Yuan, Qiuguo Zhu, Wanming Yu, and Zhibin Li. Multi-expert learning of adaptive legged locomotion. Science Robotics, 5(49):eabb2174, 2020.

[54] Ruihan Yang, Minghao Zhang, Nicklas Hansen, Huazhe Xu, and Xiaolong Wang. Learning vision-guided quadrupedal locomotion end-to-end with cross-modal transformers. In Deep RL Workshop NeurIPS 2021.

[55] Chong Zhang, Jin Jin, Jonas Frey, Nikita Rudin, Matías Mattamala, Cesar Cadena, and Marco Hutter. Resilient legged local navigation: Learning to traverse with compromised perception end-to-end. In 2024 IEEE International Conference on Robotics and Automation (ICRA), pages 34–41. IEEE, 2024.

[56] Chong Zhang, Nikita Rudin, David Hoeller, and Marco Hutter. Learning agile locomotion on risky terrains. In 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 11864–11871. IEEE, 2024.

[57] Ying Zhang, Tao Xiang, Timothy M Hospedales, and Huchuan Lu. Deep mutual learning. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 4320–4328, 2018.

[58] Shaoting Zhu, Linzhan Mou, Derun Li, Baijun Ye, Runhan Huang, and Hang Zhao. Vr-robo: A real-to-sim-to-real framework for visual robot navigation and locomotion. IEEE Robotics and Automation Letters, 2025.